

MLG

Curso de Modelos Lineares Generalizado - DEST/UFMG
Marcos Oliveira Prates

4 de agosto de 2015

- e-mail: marcosop@est.ufmg.br
- sala: 4060 / ICEx
- telefone: 3409-5932
- site: www.est.ufmg.br/~marcosop

- Modelo de Regressão Linear
 - Regressão Linear Simples
 - Regressão Linear Múltipla (forma matricial)
 - Análise de Resíduos
 - Transformação de Variáveis
 - Regressão Não Linear

- Modelos Lineares Generalizados
 - Família exponencial. Ajuste pelo método de Newton Raphson. Inferência. Seleção de Variáveis e Análise de resíduos.
 - Regressão Logística
 - Regressão de Poisson
 - Regressão Gama
- Ponto de vista clássico e Bayesiano

- Não haverá aula nos dias 08/03 e 10/03.
- Teremos 02 (duas) provas no valor de 20 pontos cada.
- Teremos a apresentação de 03 (três) trabalhos:
 - 1- Explicação e exemplo de uso de alguma função de GLM em R (10 pontos);
 - 2- Leitura de um artigo, resumo e apresentação (15 pontos);
 - 3- Trabalho prático (25 pontos);
- 10 pontos para listas, frequência e participação.
- As datas da prova serão definidas oficialmente durante o semestre.

- Referências bibliográficas:

- Ravishanker N. and Dey D. K. (2000). A First Course in Linear Model Theory. Chapman & Hall.
- Seber G. A. F. and Lee A. J. (2003). Linear Regression Analysis. Wiley.
- McCullagh P. and Nelder J. A. (1989). Generalized Linear Models. Chapman & Hall.
- Neter J., Kutner M. H., Nachtsheim, C. J. and Wasserman W. (1996). Applied Linear Statistical Models. McGraw-Hill.
- Cordeiro G. M. (2007). Modelos Lineares Generalizados. Mini curso RBRAS.
- Paula G. A. (2004). MODELOS DE REGRESSAO com apoio computacional. www.ime.usp.br/~giapaula.
- **R**, Wikipedia, etc.

- Modelos estatísticos devem ser capazes de acomodar a variabilidade inerente aos dados.
- Assim, de forma geral, um modelo estatístico pode ser escrito da seguinte forma:

$$Y = \text{componente determinística} + \text{componente aleatória}$$

- Como iremos ver no decorrer do curso, existem diversas maneiras de especificar essas componentes.
- Começaremos com o caso mais simples de uma regressão linear simples.

- Uma regressão linear simples tem como objetivo aproximar uma variável de resposta Y através de uma função linear de uma variável de interesse, ou seja,

$$Y = f(X, \beta) + \varepsilon = \beta_0 + \beta_1 X + \varepsilon$$

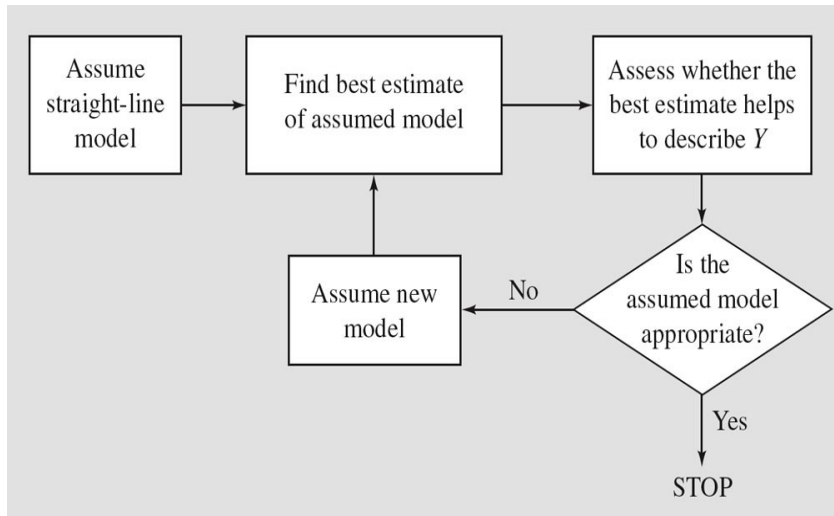
- No qual assume-se que:
 - $E(\varepsilon) = 0$
 - $V(\varepsilon) = \sigma^2$ (Homocedasticidade)
 - $Cov(\varepsilon_i, \varepsilon_j) = 0$,

em outras palavras, os erros tem média zero, variância constante e são não correlacionados.

Regressão Linear Simples

- As variável preditora X pode vir de diversas fontes
 - inputs quantitativos (valores reais, medidas)
 - transformação de variável quantitativas (\log , $\sqrt{}$, etc)
 - inputs qualitativos (“dummy” e.x. genero, classes)
- Dessa forma, um modelos de regressão consiste em 4 passos:
 - 1 Escolher o componente determinístico do modelo;
 - 2 Utilizar os dados para estimar os parâmetros do modelo;
 - 3 Especificar a distribuição do erro;
 - 4 Avaliar o modelo estatístico;

Diagrama de um Modelo de Regressão



© 2007 Thomson Higher Education

Regressão Linear Simples

- Após a escolha do modelo, devemos utilizar a informação nos dados para fazer a estimação dos parâmetros.
- O método mais utilizado é conhecido como método de mínimos quadrados, e é dados por:

$$\begin{aligned} SEQ(\beta) &= \sum_{i=1}^n (Y_i - f(X_i, \beta))^2 \\ &= \sum_{i=1}^n (Y_i - \beta_0 - X_i \beta_1)^2, \end{aligned}$$

Os estimadores de β_0 e β_1 são aqueles que minimizam o SEQ

- Diferenciando SEQ em relação a β chegamos as equações normais:

$$\begin{aligned} \frac{\partial SEQ}{\partial \beta_0} &= -2 \sum_{i=1}^n (Y_i - \beta_0 - X_i \beta_1) \\ \frac{\partial SEQ}{\partial \beta_1} &= -2 \sum_{i=1}^n X_i (Y_i - \beta_0 - X_i \beta_1) \end{aligned}$$

Regressão Linear Simples

- Quando essas derivadas parciais são igualadas a zero e resolvidas, temos que $\hat{\beta}_0$ e $\hat{\beta}_1$ são os valores que minimizam o *SEQ*:

$$\sum_{i=1}^n (Y_i - \hat{\beta}_0 - X_i \hat{\beta}_1) = 0$$


$$\sum_{i=1}^n X_i (Y_i - \hat{\beta}_0 - X_i \hat{\beta}_1) = 0$$

- Assim resolvendo ambas equações simultaneamente temos que

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})}{\sum_{i=1}^n (X_i - \bar{X})^2} = \frac{\sum_{i=1}^n X_i Y_i - n\bar{X}\bar{Y}}{\sum_{i=1}^n X_i^2 - n\bar{X}^2}$$

$$\hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{X}$$

Conceito do Estimador de Mínimos Quadrados



Regressão Linear Simples

- Dada a estimativa dos parâmetros $(\hat{\beta}_0, \hat{\beta}_1)$ temos o modelo ajustado

$$\hat{Y} = \hat{\beta}_0 + \hat{\beta}_1 X$$

Note que por construção o ponto (\bar{Y}, \bar{X}) sempre cai exatamente no modelo ajustado

- Para os valores de $X = X_i$, um dos valores do banco de dados, os valor estimado é da forma

$$\hat{Y}_i = \hat{\beta}_0 + \hat{\beta}_1 X_i, \quad i = 1, \dots, n.$$

- Os resíduos, e_i , são definidos como a diferença entre os valores observados e os valores estimados, assim:

$$e_i = Y_i - \hat{Y}_i = Y_i - (\hat{\beta}_0 + \hat{\beta}_1 X_i) \quad i = 1, \dots, n.$$

Regressão Linear Simples

- Logo temos que

$$\begin{aligned} SEQ &= \sum_{i=1}^n (Y_i - f(X_i, \beta))^2 = \sum_{i=1}^n (Y_i - \beta_0 - X_i \beta_1)^2 \\ &= \sum_{i=1}^n (Y_i - \hat{Y}_i)^2 = \sum_{i=1}^n e_i^2. \end{aligned}$$

- Propriedades dos erros

Como $(\beta_0$ e $\hat{\beta}_1)$ são estimados pelo método de mínimos quadrados temos

$$\sum_{i=1}^n (Y_i - \hat{\beta}_0 - X_i \hat{\beta}_1) = 0$$

$$\sum_{i=1}^n X_i (Y_i - \hat{\beta}_0 - X_i \hat{\beta}_1) = 0$$

portanto,

$$\sum_{i=1}^n e_i = \sum_{i=1}^n (Y_i - \hat{\beta}_0 - x_i \hat{\beta}_1) = 0 = \sum_{i=1}^n (Y_i - \hat{Y}_i)$$

$$\sum_{i=1}^n x_i e_i = \sum_{i=1}^n x_i (Y_i - \hat{\beta}_0 - x_i \hat{\beta}_1) = 0 = \sum_{i=1}^n x_i (Y_i - \hat{Y}_i)$$

Regressão Linear Simples

- Até esse momento ainda não usamos a suposição de nenhuma distribuição para o erro
- Comumente adota-se que o erro $\varepsilon \sim N(0, \sigma^2)$, isso garante que todas as suposições do modelo sejam atendidas e possibilita inferência sobre a modelagem
- Com a suposição de normalidade temos que σ^2 pode ser estimado

$$\hat{\sigma}^2 = \text{MEQ} = \frac{1}{n-2} \text{SRQ} = \frac{1}{n-2} \sum_{i=1}^n e_i^2,$$

Regressão Linear Simples

- Suponha que os dados (y_i, x_i) , sejam modelados por uma regressão linear simples e assumamos que $\varepsilon_i \stackrel{iid}{\sim} N(0, \sigma^2)$ temos que:

$$L(\beta_0, \beta_1, \sigma^2) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{1}{2\sigma^2} (y_i - \beta_0 - \beta_1 x_i)^2\right)$$

Logo,

$$\ln L = l(\beta_0, \beta_1, \sigma^2) = -\frac{n}{2} \ln 2\pi - \frac{n}{2} \ln \sigma^2 - \frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2$$

Regressão Linear Simples

diferenciando em relação aos β 's temos

$$\frac{\partial l}{\partial \beta_0} = \frac{1}{\sigma^2} \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i) = 0$$

$$\frac{\partial l}{\partial \beta_1} = \frac{1}{\sigma^2} \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i) x_i = 0$$

Resolvendo o sistema de equações, temos os mesmos estimadores do método de Mínimos Quadrados, porém

$$\frac{\partial l}{\partial \sigma^2} = -\frac{n}{2\sigma^2} + \frac{1}{2\sigma^4} \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2 = 0$$

$$\hat{\sigma}^2 = \frac{\sum_{i=1}^n (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i)^2}{n} = \frac{1}{n} \sum_{i=1}^n e_i^2$$

Regressão Linear Simples

- Assumindo que o erro possui distribuição normal independentes, podemos executar testes de hipóteses para β_0 e β_1

$$\hat{\beta}_0 \sim N\left(\beta_0, \sigma^2 \left(\frac{1}{n} + \frac{\bar{x}^2}{\sum_{i=1}^n (x_i - \bar{x})^2}\right)\right)$$

$$\hat{\beta}_1 \sim N\left(\beta_1, \sigma^2 \frac{1}{\sum_{i=1}^n (x_i - \bar{x})^2}\right)$$

- Logo para testar, $i = 0, 1$

$$\begin{cases} H_0 : \beta_i = 0 \\ H_1 : \beta_i \neq 0 \end{cases} \quad (1)$$

seguimos de forma equivalente a testes de hipóteses normais

- Assim

$$\begin{cases} H_0 : \beta_0 = 0 \\ H_1 : \beta_0 \neq 0 \end{cases} \quad (2)$$

é dado por

$$t_{obs} = \frac{\hat{\beta}_0 - 0}{s(\hat{\beta}_0)} \sim t_{n-2}.$$

Portanto, rejeita-se H_0 se $|t_{obs}| > t_{\frac{\alpha}{2}, n-2}$

- De forma equivalente temos que para β_1

$$\begin{cases} H_0 : \beta_1 = 0 \\ H_1 : \beta_1 \neq 0, \end{cases} \quad (3)$$

$$t_{obs} = \frac{\hat{\beta}_1 - 0}{s(\hat{\beta}_1)} \sim t_{n-2}.$$

Portanto, rejeita-se H_0 se $|t_{obs}| > t_{\frac{\alpha}{2}, n-2}$

- Antes de seguirmos com a análise de regressão linear, vamos dar uma pausa para re-ver ou ver algumas propriedades matriciais importantes para a continuação do curso.
- **Espaço Vetorial:** O espaço vetorial é um conjunto

$$\mathcal{V}_n = \{ \mathbf{v}_i = (v_{i1}, \dots, v_{in}), v_{ij} \in \mathfrak{R}, i = 1, \dots, l \}$$

no qual é fechado sobre a adição, multiplicação por escalar, e contém o vetor $\mathbf{0}$.

- **Vetores Dependentes e Vetore Independentes:** Seja $\{ \mathbf{v}_1, \dots, \mathbf{v}_m \}$ um conjunto de vetores n -dimensionais pertencentes a \mathcal{V}_n . Esse m vetores são ditos linearmente dependentes **se e somente se** existir escalares c_1, \dots, c_m , com pelo menos um diferente de zero, tal que $\sum_{i=1}^m c_i \mathbf{v}_i = \mathbf{0}$.
- Se $c_1 = \dots = c_m = 0$ para que $\sum_{i=1}^m c_i \mathbf{v}_i = \mathbf{0}$, então $\{ \mathbf{v}_1, \dots, \mathbf{v}_m \}$ são ditos independentes.

- Regras de Adição de matrizes. Sejam as matrizes A, B, C $m \times n$ e a, b, c escalares:

1 $(A + B) + C = A + (B + C)$

2 $A + B = B + A$

3 $A + (-A) = (-A) + A = 0$

4 $A + 0 = 0 + A$

5 $c(A + B) = cA + cB$

6 $(a + b)C = aC + bC$

7 $abC = a(bC) = b(aC)$

8 $0A = 0$

9 $1A = A$

- Regras de Multiplicação de matrizes. Seja A uma matriz $m \times n$ e B, C matrizes com a dimensão apropriada:
 - 1 $(AB)C = A(BC)$
 - 2 $A(B + C) = AB + AC$
 - 3 $(A + B)C = AC + BC$
 - 4 $a(BC) = (aB)C = B(aC)$
 - 5 $I_m A = A I_n = A$
 - 6 $0_m A = A 0_n = 0$
- É importante frizar que no caso matricial $AB \neq BA$ em geral, em alguns casos podemos ter AB definido e BA não.

- Regras de Transposição de matrizes. Seja A e B conformes sobre a adição e A e C conformes com a multiplicação:
 - 1 $(A')' = A$
 - 2 $(aA + bB)' = aA' + bB'$
 - 3 $(cA)' = cA'$
 - 4 $A' = B'$ se e somente se $A = B$
 - 5 $(AC)' = C'A'$
- **Matriz simétrica:** Uma matriz é dita simétrica se $A = A'$.

- **Traço da Matriz:** O traço da matriz é definido como a soma dos elementos da diagonal de A . Seja $A_{n \times n}$ então $tr(A) = \sum_{i=1}^n a_{ii}$.
- Propriedades do traço:
 - 1 $tr(I_n) = n$
 - 2 $tr(aA + bB) = atr(A) + btr(B)$
 - 3 $tr(AB) = tr(BA)$
 - 4 $tr(ABC) = tr(CAB) = tr(BCA)$
 - 5 $tr(A) = tr(A')$
 - 6 $tr(AA') = tr(A'A) = \sum_{i,j=1}^n a_{ij}^2$

Propriedades Matricial

- **Determinante de Matriz:** O determinante de uma matriz $A_{n \times n}$ é um escalar dado porque

$$|A| = \sum_{j=1}^n a_{ij}(-1)^{i+j}|M_{ij}|, \text{ para qual quer } i \text{ fixado}$$

onde M_{ij} é matriz obtida removendo-se a i -ésima linha e j -ésima coluna de A .

- Propriedades do determinante:

- 1 $|A| = |A'|$
- 2 $|cA| = c^n |A|$
- 3 $|AB| = |A||B|$
- 4 Se A é diagonal ou triangular inferior (superior) então $|A| = \prod_{i=1}^n a_{ii}$
- 5 Se duas linhas ou colunas de A são iguais, então $|A| = 0$
- 6 Se tem linhas ou colunas iguais a 0, então $|A| = 0$

- Propriedades do determinante:

- 7 Se as linhas (colunas) são linearmente dependentes, então $|A| = 0$
- 8 Seja B obtido multiplicando uma linha ou coluna A por um escalar c , então $|B| = c|A|$
- 9 Seja B obtido trocando de posição uma coluna ou linha de A , então $|B| = -|A|$
- 10 Seja $A_{m \times n}$ e $B_{n \times m}$, então $|I_m + AB| = |I_n + BA|$

- **Inverso de uma Matriz:** Seja $A_{n \times n}$. Se existe $B_{n \times n}$ tal que $AB = I_n$ (e $BA = I_n$), então B é chamado de inverso de A e denotamos por A^{-1} .
- Propriedades do inverso:
 - 1 A^{-1} é unico
 - 2 $(AB)^{-1} = B^{-1}A^{-1}$
 - 3 $(cA)^{-1} = (Ac)^{-1} = \frac{A^{-1}}{c}$
 - 4 Se $|A| \neq 0$, então A' e A^{-1} são não singulares e $(A')^{-1} = (A^{-1})'$
 - 5 $(A + BCD)^{-1} = A^{-1} - A^{-1}B(C^{-1} + DA^{-1}B)^{-1}DA^{-1}$
(Sherman-Morrisson-Woodbury Theorem)
 - 6 $|A^{-1}| = |A|^{-1}$

- **Espaço das Colunas de uma Matriz:** Seja $A_{m \times n}$ na qual as colunas m -dimensionais são $\mathbf{a}_1, \dots, \mathbf{a}_n$. O espaço vetorial gerado pelas n colunas de A é chamado de espaço das colunas de A ($C(A)$). A dimensão do espaço das colunas de A é o número de colunas linearmente independentes.
- **Espaço Nulo de uma Matriz:** O espaço nulo, $\mathcal{N}(A)$, de uma matriz $A_{m \times n}$ consiste de todos os vetores n -dimensionais \mathbf{x} tal que $A\mathbf{x} = \mathbf{0}$, ou seja,

$$\mathcal{N}(A) = \{\mathbf{x} \in \mathbb{R}^n \text{ tal que } A\mathbf{x} = \mathbf{0}\}$$

- Propriedades do espaço de colunas:

- 1 $\dim[C(A)] = n - \dim[\mathcal{N}(A)]$
- 2 $\mathcal{N}(A) = \{C(A)\}^\perp$
- 3 $C(A'A) = C(A')$
- 4 Para qualquer A e B , $C(AB) \subseteq C(A)$

Propriedades Matricial

- **Rank de uma Matriz:** Seja $A_{m \times n}$. Dizemos que a matriz A possui rank completo de linha se $r(A) = m$ (somente se $m \leq n$), e possui rank completo de coluna se $r(A) = n$ (somente se $n \leq m$). Dizemos que uma matriz tem rank r ($r(A) = r$) se o rank das colunas é igual ao rank das linhas iguais a r .
- Propriedades de rank:
 - 1 $A_{m \times n}$ tem rank r se a maior sub-matriz não singular de A possui tamanho r .
 - 2 Para $A_{m \times n}$, $r(A) \leq \min(m, n)$
 - 3 $r(A + B) \leq r(A) + r(B)$
 - 4 $r(AB) \leq \min\{r(A), r(B)\}$
 - 5 Para matrizes não singulares A, B e uma matriz qualquer C

$$r(C) = r(AC) = r(CB) = r(ACB)$$

- 6 $r(A) = r(A') = r(A'A) = r(AA')$
- 7 $r(A, b) \geq r(A)$, isso é, adicionar uma coluna em A nunca reduz o seu rank

- Seja as seguintes notações:
 - $A_{n \times n}$: matriz de constantes
 - $X_{n \times 1}$: vetor de variáveis (ou parâmetros)
 - $a_{n \times 1}$: vetor de constantes .
- Derivadas de Matrizes:
 - $\frac{\partial a^T X}{\partial X} = a$
 - $\frac{\partial X^T X}{\partial X} = 2X$
 - $\frac{\partial a^T A x}{\partial x} = A' a$
 - $\frac{\partial x^T A x}{\partial x} = A x + A^T x$

- Seja $\mathbf{X}_{n \times 1}$ um vetor de variáveis aleatórias e $\mathbf{A}_{n \times n}$ uma matriz simétrica. A $E(\mathbf{X}) = \boldsymbol{\mu}$ e a $\text{Var}(\mathbf{X}) = \boldsymbol{\Sigma} = (\sigma_{ij})$. Temos que:

$$E(\mathbf{X}'\mathbf{A}\mathbf{X}) = \text{tr}(\mathbf{A}\boldsymbol{\Sigma}) + \boldsymbol{\mu}'\mathbf{A}\boldsymbol{\mu}$$

- Prova

$$\begin{aligned} E(\mathbf{X}'\mathbf{A}\mathbf{X}) &= \text{tr}(E[\mathbf{X}'\mathbf{A}\mathbf{X}]) \\ &= E[\text{tr}(\mathbf{X}'\mathbf{A}\mathbf{X})] = E[\text{tr}(\mathbf{A}\mathbf{X}\mathbf{X}')] \\ &= \text{tr}[E(\mathbf{A}\mathbf{X}\mathbf{X}')] = \text{tr}[\mathbf{A}E(\mathbf{X}\mathbf{X}')] \\ &= \text{tr}[\mathbf{A}(\text{Var}(\mathbf{X}) + \boldsymbol{\mu}\boldsymbol{\mu}')] = \text{tr}(\mathbf{A}\boldsymbol{\Sigma}) + \text{tr}(\mathbf{A}\boldsymbol{\mu}\boldsymbol{\mu}') \\ &= \text{tr}(\mathbf{A}\boldsymbol{\Sigma}) + \text{tr}(\boldsymbol{\mu}'\mathbf{A}\boldsymbol{\mu}) \\ &= \text{tr}(\mathbf{A}\boldsymbol{\Sigma}) + \boldsymbol{\mu}'\mathbf{A}\boldsymbol{\mu} \end{aligned}$$

Regressão Linear Múltipla

- Assim, como na regressão linear simples, uma regressão linear múltipla supõe que função de regressão $E(Y|X)$ é linearmente dependente dos preditores X_1, \dots, X_p .
- Regressões lineares são simples e comumente fornecem uma descrição adequada e interpretável de como as variáveis exploratórias afetam a resposta.

- Suponha que temos $X' = (X_1, \dots, X_p)$ e queremos prever uma resposta Y . Uma regressão linear é da formado

$$Y = \beta_0 + \sum_{i=1}^p X_i \beta_i$$

onde β_i não são conhecidos.

- As variáveis X_i podem vir de diferentes fontes
 - inputs quantitativos (valores reais, medidas)
 - transformação de inputs quantitativos ($\log, \sqrt{\cdot}$, etc)
 - expansão de base ($X_2 = X_1^2, X_3 = X_1^3$)
 - inputs qualitativos (“dummy” e.x. genero, classes)
 - interação ($X_3 = X_1 \cdot X_2$)

- Normalmente tem-se um banco de observações $(x_1, y_1), \dots, (x_n, y_n)$, no qual o objetivo é estimar os parâmetros β .
- Ao estender a noção de regressão simples para regressão múltipla o método de mínimos quadrados continua sendo utilizado, no qual as estimativas de β são escolhidas derivando o *SEQ* em relação a β_0, \dots, β_k

$$\begin{aligned} SEQ(\beta) &= \sum_{i=1}^n (Y_i - f(X_i, \beta))^2 \\ &= \sum_{i=1}^n (Y_i - \beta_0 - \sum_{j=1}^k X_{ij}\beta_j)^2. \end{aligned}$$

Intuição do métodos de mínimos quadrados

Elements of Statistical Learning (2nd Ed.) ©Hastie, Tibshirani & Friedman 2009 Chap 3




FIGURE 3.1. *Linear least squares fitting with $X \in \mathbb{R}^2$. We seek the linear function of X that minimizes the sum of squared residuals from Y .*

- Podemos representar tanto a regressão simples, assim como a regressão múltipla na forma matricial. Seja $p = k + 1$ and

$$\mathbf{Y}_{n \times 1} = \begin{pmatrix} Y_1 \\ Y_2 \\ \vdots \\ Y_n \end{pmatrix}, \quad \mathbf{X}_{n \times p} = \begin{pmatrix} 1 & X_{11} & \cdots & X_{1k} \\ 1 & X_{21} & \cdots & X_{2k} \\ \vdots & \vdots & \ddots & \vdots \\ 1 & X_{n1} & \cdots & X_{nk} \end{pmatrix}, \quad \boldsymbol{\beta}_{p \times 1} = \begin{pmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_k \end{pmatrix}, \quad \boldsymbol{\varepsilon}_{n \times 1} = \begin{pmatrix} \varepsilon_1 \\ \varepsilon_2 \\ \vdots \\ \varepsilon_n \end{pmatrix}.$$

Aqui, $\mathbf{X}_{n \times p}$ é chamado de matriz de desenho. Dessa forma o modelo de regressão pode escrito como:

$$\mathbf{Y}_{n \times 1} = \mathbf{X}_{n \times p} \boldsymbol{\beta}_{p \times 1} + \boldsymbol{\varepsilon}_{n \times 1},$$

- Nesse caso, seja \mathbf{X} uma matriz $n \times p$, onde a primeira coluna de \mathbf{X} é de 1's.
- Defina \mathbf{Y} como um vetor $n \times 1$ de respostas. Logo

$$SEQ(\beta) = (\mathbf{Y} - \mathbf{X}\beta)'(\mathbf{Y} - \mathbf{X}\beta)$$

(mostrar no quadro equivalência)

- Para minimizar SEQ devemos derivar em relação a β e igualar a 0

$$\frac{\partial SEQ(\beta)}{\partial \beta} = -2\mathbf{X}^\top (\mathbf{y} - \mathbf{X}\beta) \equiv 0 \text{ (Verificar)}$$

- Seja $\hat{\beta} = \begin{pmatrix} \hat{\beta}_0 \\ \hat{\beta}_1 \end{pmatrix}$. As equações normais são da forma

$$\mathbf{X}'\mathbf{X}\hat{\beta} = \mathbf{X}'\mathbf{Y}.$$

- Assumindo que \mathbf{X} tem posto completo e resolvendo as equações normais temos que

$$\hat{\beta} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y}$$

- No caso da RLS podemos visualizar as matrizes

$$\mathbf{X}'\mathbf{Y} = \begin{pmatrix} \sum_{i=1}^n Y_i \\ \sum_{i=1}^n X_i Y_i \end{pmatrix}, \quad \mathbf{X}'\mathbf{X} = \begin{pmatrix} n & \sum_{i=1}^n X_i \\ \sum_{i=1}^n X_i & \sum_{i=1}^n X_i^2 \end{pmatrix}$$

e

$$(\mathbf{X}'\mathbf{X})^{-1} = \frac{1}{nS_{XX}} \begin{pmatrix} \sum_{i=1}^n X_i^2 & -n\bar{X} \\ -n\bar{X} & n \end{pmatrix} = \begin{pmatrix} \frac{1}{n} + \frac{\bar{X}^2}{S_{XX}} & -\frac{\bar{X}}{S_{XX}} \\ -\frac{\bar{X}}{S_{XX}} & \frac{1}{S_{XX}} \end{pmatrix}.$$

- Assim temos o que o valor estimado pela regressão é da forma

$$\hat{y} = \mathbf{X}\hat{\beta} = \mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y} \quad (4)$$

$$\hat{\mathbf{Y}}_{n \times 1} = \begin{pmatrix} \hat{Y}_1 \\ \hat{Y}_2 \\ \vdots \\ \hat{Y}_n \end{pmatrix} = \mathbf{X}\hat{\beta} = \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1} \mathbf{X}'\mathbf{Y} = \underset{n \times n}{\mathbf{H}} \underset{n \times 1}{\mathbf{Y}},$$

onde

$$\underset{n \times n}{\mathbf{H}} = \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1} \mathbf{X}'$$

é chamada de **Hat Matrix** ou **Matriz de projeção**.

- Propriedades da matriz de projeção:
 - \mathbf{H} é simétrico, ou seja, $\mathbf{H}' = \mathbf{H}$
 - \mathbf{H} é idepotente, ou seja, $\mathbf{H}^2 = \mathbf{H}$
 - $tr(\mathbf{H}) = p$ onde p é o posto de \mathbf{X}
 - \mathbf{H} é a matriz de projeção no plano gerado pelas colunas de \mathbf{X} , ou seja, $\mathbf{HX} = \mathbf{X}$
 - Quais são os autovalores de \mathbf{H} ?




FIGURE 3.2. *The N -dimensional geometry of least squares regression with two predictors. The outcome vector \mathbf{y} is orthogonally projected onto the hyperplane spanned by the input vectors \mathbf{x}_1 and \mathbf{x}_2 . The projection $\hat{\mathbf{y}}$ represents the vector of the least squares predictions*

- Quando \mathbf{X} não possui posto completo, então $\hat{\beta}$ não pode ser estimado de forma única
- Porém $\hat{y} = \mathbf{X}\hat{\beta}$ é único, pois $\mathbf{H} = \mathbf{X}(\mathbf{X}'\mathbf{X})^{-}\mathbf{X}'$ unicamente define a projeção de y no espaço gerado por \mathbf{X}
- Portanto apesar das infinitas soluções para β temos que \hat{y} continua sendo estimado de forma única

- Até o momento não foi necessária nenhuma hipótese sobre o modelo.
- Para inferência vamos supor que

$$\begin{aligned} Y &= \mathbf{X}\beta + \varepsilon \\ \varepsilon &\sim N(0, \sigma^2 \mathbf{I}) \end{aligned}$$

- Pois

$$\text{Var}(\mathbf{Y}) = \text{Var}(\varepsilon) = \begin{pmatrix} \text{Var}(\varepsilon_1) & \text{Cov}(\varepsilon_1, \varepsilon_2) & \cdots & \text{Cov}(\varepsilon_1, \varepsilon_n) \\ \text{Cov}(\varepsilon_2, \varepsilon_1) & \text{Var}(\varepsilon_2) & \cdots & \text{Cov}(\varepsilon_2, \varepsilon_n) \\ \vdots & \vdots & \ddots & \vdots \\ \text{Cov}(\varepsilon_n, \varepsilon_1) & \text{Cov}(\varepsilon_n, \varepsilon_2) & \cdots & \text{Var}(\varepsilon_n) \end{pmatrix} = \sigma^2 \mathbf{I}_{n \times n},$$

onde \mathbf{I} é a matriz de identidade $n \times n$.

- Dessa forma temos que

$$\text{Var}(\hat{\beta}) = (\mathbf{X}'\mathbf{X})^{-1}\sigma^2$$

- Sob a hipótese de normalidade é simples mostrar que

$$\hat{\beta} \sim N(\beta, (\mathbf{X}^\top \mathbf{X})^{-1}\sigma^2)$$

- Resíduos

O vetor de resíduos é dado por

$$\underset{n \times 1}{\mathbf{e}} = \begin{pmatrix} e_1 \\ e_2 \\ \vdots \\ e_n \end{pmatrix} = \mathbf{Y} - \hat{\mathbf{Y}} = \mathbf{Y} - \mathbf{H}\mathbf{Y} = (\mathbf{I} - \mathbf{H})\mathbf{Y}.$$

É fácil mostrar que a matriz $(\mathbf{I} - \mathbf{H})$ também é *simétrica* e *idepotente*.

- Estimando a variância do erro

A soma quadrática dos erros é dada por

$$\text{SSE} = e'e = \sum_{i=1}^n e_i^2.$$

Dessa forma o estimador apropriado para σ^2 é

$$\hat{\sigma}^2 = \text{MSE} = \frac{1}{n-p} \text{SSE} = \frac{1}{n-p} \sum_{i=1}^n e_i^2,$$

- Pela normalidade podemos mostrar

$$(N-p)\hat{\sigma}^2 \sim \sigma^2 \chi_{n-p}^2 \text{ (verifique)}$$

- Matriz de Covariância dos Resíduos

$$\begin{aligned}\text{Var}(e) &= \text{Cov}((\mathbf{I} - \mathbf{H})\mathbf{Y}, (\mathbf{I} - \mathbf{H})\mathbf{Y}) \\ &= (\mathbf{I} - \mathbf{H})\text{Var}(\mathbf{Y})(\mathbf{I} - \mathbf{H})' = \sigma^2(\mathbf{I} - \mathbf{H}).\end{aligned}$$

- Logo, a matriz estimada de covariância para os resíduos é dada por

$$\widehat{\text{Var}}(e) = \text{MSE}(\mathbf{I} - \mathbf{H}).$$

- Antes de apresentar a definição do g-inverso apresentamos os resultados:
- Seja \mathbf{A} e \mathbf{B} matrizes $m \times n$. Seja $\mathbf{C}_{p \times m}$ e $\mathbf{D}_{n \times p}$.
 - 1 se $\mathbf{CA} = \mathbf{CB}$ então $\mathbf{A} = \mathbf{B}$.
 - 2 se $\mathbf{AD} = \mathbf{BD}$ então $\mathbf{A} = \mathbf{B}$.
 - 3 se $\mathbf{CAD} = \mathbf{CBD}$ então $\mathbf{A} = \mathbf{B}$.
 - 4 $\mathbf{AB} = \mathbf{AC}$ se e somente se $\mathbf{A}'\mathbf{AB} = \mathbf{A}'\mathbf{AC}$
 - 5 $\mathbf{EA}' = \mathbf{FA}'$ se e somente se $\mathbf{EA}'\mathbf{A} = \mathbf{FA}'\mathbf{A}$

- **G-inverso:** Um inverso generalizado (g-inverso) de uma matriz $m \times n$ A é uma matriz $\mathbf{G}_{n \times m}$ se ela satisfaz a seguinte relação

$$\mathbf{AGA} = \mathbf{A}$$

- Denotamos o g-inverso por \mathbf{A}^-
- Teorema: A matriz \mathbf{G} g-inverso de uma matriz real \mathbf{A} sempre existe. E $\mathbf{G} = \mathbf{A}^{-1}$ se \mathbf{A} é não singular.

- Seja $\mathbf{A}_{m \times n}$ de posto r . Então
 - $\mathbf{A}^-\mathbf{A}$ e $\mathbf{A}\mathbf{A}^-$ são idepotente
 - $(\mathbf{I} - \mathbf{A}^-\mathbf{A})$ e $(\mathbf{I} - \mathbf{A}\mathbf{A}^-)$ são idepotente
- Seja \mathbf{G} g-inverso de $\mathbf{A}'\mathbf{A}$, então
 - \mathbf{G}' é g-inverso de $\mathbf{A}'\mathbf{A}$
 - \mathbf{GA}' é g-inverso \mathbf{A} , tal que $\mathbf{AGA}'\mathbf{A} = \mathbf{A}$
 - \mathbf{AGA}' é invariante a escolha de \mathbf{G} , ou seja,

$$\mathbf{AG}_1\mathbf{A}' = \mathbf{AG}_2\mathbf{A}'$$

- \mathbf{AGA}' é simétrica

- Como comentamos, a não ser que $r(\mathbf{X}) = p$, $\tilde{\beta}$ não é único.
- Apesar de no modelo de posto completo podermos estimar qualquer função de β devemos nos restringir apenas algumas funções de β quando $r(\mathbf{X}) < p$.
- Essas funções são chamadas de funções estimáveis
- **Definição:** Uma função linear paramétrica $\mathbf{c}'\beta$ é chamada estimável de β se existe um vetor n -dimensional $\mathbf{t} = (t_1, \dots, t_n)'$ tal que a esperança da combinação linear $\mathbf{t}'\mathbf{y} = \mathbf{c}'\beta$, isto é,

$$E(\mathbf{t}'\mathbf{y}) = \mathbf{c}'\beta$$

- Ou seja, $\mathbf{c}'\beta$ se existe um função linear de \mathbf{y} tal que o valor esperado é igual à $\mathbf{c}'\beta$.

- Se $r(\mathbf{X}) = p$ então qualquer função linear de β é estimável.
- Esse não é o caso para modelos no qual $r(\mathbf{X}) < p$. Nesses casos, devemos verificar que a função de β é estimável.
- Para garantir que uma função $\mathbf{c}'\beta$ devemos verificar:
 - Uma função $\mathbf{c}'\beta$ é estimável se e somente se $\mathbf{c}' = \mathbf{t}'\mathbf{X}$ para um vetor \mathbf{t}
 - Uma função $\mathbf{c}'\beta$ é estimável se e somente se $\mathbf{c}' = \mathbf{c}'\mathbf{W}$ onde $\mathbf{W} = \mathbf{GX}'\mathbf{X}$.

- Desses resultados é possível mostrar que:
 - O valor esperado de qualquer observação é estimável.
 - Qualquer combinação linear de funções estimáveis é estimável.
 - Dado uma função estimável $\mathbf{c}'\beta$, a quantidade $\mathbf{c}'\tilde{\beta}$ é invariante a escolha de $\tilde{\beta}$.

O Teorema de Gauss-Markov

- Seja $\mathbf{c}'\beta$ uma função estimável de β e seja $\tilde{\beta}$ uma solução qualquer para as equações normais.
- O Teorema de Gauss-Markov afirma $\mathbf{c}'\tilde{\beta}$ é o melhor estimador não viesado de $\mathbf{c}'\beta$ com variância $\text{Var}(\mathbf{c}'\tilde{\beta}) = \sigma^2 \mathbf{c}'\mathbf{G}\mathbf{c}$.
- Se $\tilde{\beta} = \hat{\beta}$ então $\text{Var}(\mathbf{c}'\hat{\beta}) = \sigma^2 \mathbf{c}'(\mathbf{X}'\mathbf{X})^{-1}\mathbf{c}$.