

UNIVERSIDADE FEDERAL DE ALFENAS
UNIFAL-MG

Pórtia Piscitelli Cavalcanti

Experimental Designs: um pacote R para análise de
experimentos

PÓRTYA PISCITELLI CAVALCANTI

**EXPERIMENTAL DESIGNS: UM PACOTE R PARA ANÁLISE DE
EXPERIMENTOS**

Trabalho de conclusão de curso apresentado como parte dos requisitos para a obtenção do título de Graduada em Biotecnologia pela Universidade Federal de Alfenas (Unifal-MG).

Área de concentração: Estatística Experimental.

Orientador: Prof. Dr. Eric Batista Ferreira.

Resumo

Os experimentos variam de uma pesquisa para outra; porém, todos eles são regidos por alguns princípios básicos, necessários para que as conclusões obtidas se tornem válidas. De acordo com os princípios necessários (repetição, casualização, controle local) têm-se os delineamentos experimentais. Quando mais de um fator deve ser estudado simultaneamente, utilizam-se os experimentos fatoriais e quando se quer testar dois (ou mais) fatores, porém existem restrições no processo de casualização, são utilizados os experimentos em parcelas subdivididas, onde as parcelas são divididas em subparcelas. Tratamentos adicionais podem ser interessantes para se estudar o efeito de um tratamento extra ou uma testemunha. O procedimento de análise dos resultados obtidos inclui a análise de variância, porém para a comparação múltipla das médias é empregado um de diferentes testes, (como o teste de Tukey) para tratamentos qualitativos e ajustes de modelos de regressão linear para tratamentos quantitativos. Para esse procedimento, são amplamente utilizados softwares livres e gratuitos como o software R; este possui código aberto, o que permite a modificação e otimização de funções nessa linguagem. Com a criação da biblioteca de funções *ExpDes*, que realiza a análise de variância, testes de comparação múltipla de médias e ajustes de modelos de regressão linear em uma só rodada, o tratamento estatístico dos dados experimentais se tornou mais rápido, prático e de fácil compreensão, principalmente para usuários não estatísticos.

Sumário

1	Introdução	4
2	Objetivos	6
3	Justificativa	7
4	Fundamentação teórica	9
4.1	Delineamento Inteiramente Casualizado	11
4.2	Delineamento em Blocos Casualizados	13
4.3	Delineamento em Quadrado Latino	15
4.4	Experimentos em esquema fatorial	17
4.5	Experimentos em esquema de parcelas subdivididas	25
4.6	Tratamento Adicional	29
4.7	Teste de Normalidade de Shapiro-Wilk	38
4.8	Regressão Linear na Análise de Variância	40
4.9	Testes de comparação múltipla de médias	43
4.9.1	Teste t de Student (LSD)	43
4.9.2	Teste t de Student com proteção de Bonferroni	44
4.9.3	Teste de Tukey	45
4.9.4	Teste de Duncan	45
4.9.5	Teste de Student-Newman-Keuls (SNK)	47
4.9.6	Teste de Scott-Knott	47
5	Material e Métodos	49
6	Resultados e Discussão	51
6.0.7	Sub-Rotinas	51
6.0.8	Rotinas	54
6.0.9	Pacote	83
7	Difusão de Tecnologia	84
7.1	Fases de Teste e Divulgação	84
7.2	Propriedade Intelectual	85
8	Conclusões	86
9	Referências bibliográficas	87

1 Introdução

A pesquisa científica está constantemente utilizando-se de experimentos para provar suas hipóteses. Os experimentos são métodos de pesquisa explicativa em que é imposta ou controlada a manifestação de uma ou mais características explanatórias das unidades da amostra, através de imposição de níveis (MACHADO et al., 2005). É claro que os experimentos variam de uma pesquisa para outra; porém, todos eles são regidos por alguns princípios básicos, necessários para que as conclusões obtidas se tornem válidas.

Quando se realiza um experimento, é preciso escolher uma unidade para experimentação, para a colheita dos dados que deverão refletir os efeitos dos tratamentos (GOMES, 2009). Para utilização da metodologia estatística nos resultados de um experimento, é necessário que o mesmo tenha considerado pelo menos os princípios da repetição e da casualização, a fim de que se possa obter uma estimativa válida para o erro experimental, que nos permite a aplicação dos testes de significância.

Ao se fazer um experimento considerando apenas esses dois princípios, tem-se o Delineamento Inteiramente Casualizado (DIC). Contudo, se as condições ambientais forem heterogêneas em uma direção, deve-se utilizar o princípio do controle local, estabelecendo, então, os blocos no Delineamento em Blocos Casualizados (DBC). Já para condições duplamente heterogêneas, tornando necessário o controle dos dois tipos de heterogeneidade, utiliza-se o Delineamento em Quadrado Latino (DQL) (BANZATTO & KRONKA, 2006).

Existem casos em que dois ou mais fatores devem ser estudados simultaneamente, para que se possa conduzir a resultados de interesse. Para tanto, utilizam-se os experimentos fatoriais, que são aqueles nos quais são estudados, ao mesmo tempo, os efeitos de dois ou mais tipos de tratamentos ou fatores e o interesse se dá pela interação entre estes.

Quando, num mesmo ensaio, se quer testar dois (ou mais) fatores, mas em condições experimentais que apresentam restrições no processo de casualização devido a maneira de implantação do experimento, por exemplo: variedades e adubações, espaçamentos e irrigações, variedades e épocas de plantio, são utilizados os experimentos em parcelas subdivididas, onde as parcelas são divididas em subparcelas (que constituem a unidade básica para fins de análise estatística).

Em alguns esquemas de análise, como fatorial ou parcelas subdivididas, é comum que se queira estudar o efeito de um tratamento extra ou uma testemunha, que se torna um tratamento adicional ao experimento. Este tratamento adicional é realizado concomitantemente com o experimento, porém é analisado separadamente por contrastes entre ele e os tratamentos (HEALY, 1956).

De acordo com Machado et al. (2005), os delineamentos experimentais podem apresentar fatores diferentes. De uma maneira geral, estes podem ser fatores qualitativos, se forem expressos por uma variável nominal e os seus níveis na amostra constituírem o conjunto de todos os níveis sob consideração na população objetivo, ou fatores quantitativos, se forem expressos por uma variável de escala intervalar ou racional, contínua ou discreta, definida em um intervalo cujos níveis são valores bem definidos dessa variável.

Em ambos os casos o procedimento de análise dos resultados obtidos inclui a análise de variância (ANAVA), técnica que permite fazer partições do número de graus de liberdade e das somas de quadrados, com cada uma das partes proporcionando uma estimativa de variância (denominada quadrado médio) (MACHADO et al., 2005). Porém para a comparação múltipla das médias são empregados diferentes testes, como o teste de Tukey para tratamentos qualitativos e a regressão linear para tratamentos quantitativos.

Segundo Gomes (2009), a análise de variância tal como é feita usualmente pressupõe a independência dos diversos tratamentos utilizados. Quando esta hipótese não se verifica, a análise da variância deve refletir a dependência entre os tratamentos, sob pena de não ser válida. Assim acontece no caso de tratamentos quantitativos e se justifica a existência de uma correspondência funcional (chamada equação de regressão) que ligue os valores dos tratamentos aos dados analisados.

Para a análise de delineamentos experimentais, são amplamente utilizados softwares livres e gratuitos como o Sisvar (FERREIRA, 2008) e o R (R DEVELOPMENT CORE TEAM, 2010). Este último software disponibiliza uma grande variedade de métodos estatísticos (modelagem linear e não-linear, testes estatísticos clássicos, séries temporais, classificação, métodos multivariados, etc) e técnicas gráficas. Ele se presta a diversas funções, desde uma calculadora científica, passando pela integração e derivação de funções matemáticas, até a realização de complexas análises estatísticas.

Por ser um software de código aberto, ou seja, por permitir que seu usuário veja e altere o código de suas funções, otimizações de funções em linguagem R podem ser de grande utilidade, poupando tempo e facilitando a análise e entendimento dos resultados.

2 Objetivos

Criar um pacote (biblioteca de funções) para analisar experimentos em delineamentos simples, ou seja, com apenas um fator, como experimentos em DIC, DBC e DQL, experimentos em esquema de fatorial duplo (em DIC e DBC), em esquema de fatorial triplo (em DIC e DBC), em esquema de fatorial duplo com um tratamento adicional (em DIC e DBC), em esquema de fatorial triplo com um tratamento adicional (em DIC e DBC) e em esquema de parcelas subdivididas (em DIC e DBC). Tais funções devem realizar análise de variância e testes de comparação múltipla de médias (teste de Tukey, teste de Student-Newman-Keuls, teste de Scott-Knott, teste de Duncan, teste t de Student e teste t com proteção de Bonferroni) e ajuste de modelos de regressão. Todas as análises desejadas para um experimento devem ser feitas em uma só rodada, ou seja, em uma única execução da função.

3 Justificativa

Delineamentos experimentais são amplamente utilizados por pesquisadores em todos os campos de investigação. Para a análise desses delineamentos no software R, normalmente, uma série de comandos é necessária para que este informe a análise de variância do experimento e, separadamente, outros comandos para a realização de um teste específico ou análise de regressão. Sendo realizados separadamente, esses procedimentos podem ser bastante trabalhosos e, no caso da regressão, erros de interpretação e de análise podem facilmente ocorrer.

O software R dispõe de um conjunto de pacotes básicos e outro de pacotes adicionais ou contriuidos, que devem ser instalados separadamente e carregados no momento do uso. Quando se deseja fazer o teste de Tukey, por exemplo, após a análise de variância, pode-se usar a função *HSD.test()*, do pacote *agricolae*, que deve ser instalado e carregado separadamente.

No caso do teste de Tukey, além de exigir que o usuário carregue outro pacote, digite mais uma linha de comando (que demanda que ele consulte o resultado da ANAVA anteriormente feita), a saída (output) da função *HSD.test()* é confusa e repetitiva.

Quando os tratamentos são quantitativos e o usuário ajusta um modelo de regressão usando as funções *lm()* e *anova(lm())*, ele pode se esquecer que está fora do contexto de análise da variância, e calcular o coeficiente de determinação do modelo ajustado como

$$R^2 = 1 - \frac{SQR}{SQT}$$

em que *SQR* é a soma de quadrados do resíduo e *SQT* a soma de quadrados total; enquanto deveria calcular o mesmo coeficiente como sendo

$$R^2 = 1 - \frac{SQR}{SQTrat}$$

em que *SQTrat* é a soma de quadrados de tratamento. Ou seja, no contexto da experimentação o modelo de regressão é ajustado às médias dos tratamentos excetuando-se a variação devida ao erro experimental e aos controles locais (blocos).

Em outras palavras, para obter estimativas corretas do R^2 dos modelos ajustados e um correto valor do teste F para os efeitos (linear, quadrático, etc), o usuário deve consultar o valor da soma de quadrados de tratamentos da ANAVA, estimar por diferença a soma de quadrados de desvios de regressão e refazer os testes F "na mão". Esse procedimento, além de trabalhoso, pode passar despercebido por usuários acostumados com softwares menos exigentes, como o Sisvar.

Experimentos que possuem tratamentos adicionais também exigem, tanto no R quanto em outros softwares, a execução de pelo menos duas análises separadas para posterior concatenação desses resultados em uma só tabela da ANAVA.

Com a criação de uma biblioteca com funções que realizem essas análises em uma só

rodada, o tratamento estatístico dos dados experimentais se tornaria mais rápido, prático e de fácil compreensão, principalmente para usuários não estatísticos.

4 Fundamentação teórica

Em cada experimento (ou ensaio) existem unidades experimentais ou parcelas, que serão medidas e que receberão os métodos em estudo, que são os tratamentos. O modo de dispor as parcelas no ensaio chama-se delineamento experimental (*experimental design*, em inglês).

Num experimento, como norma geral, cada tratamento deve ser aplicado a pelo menos duas parcelas, isto é, deve haver repetição. Na prática, há, quase sempre, pelo menos três ou quatro repetições, para todos os tratamentos. E esse número pode ser bem maior para obter maior precisão.

Além da exigência da repetição, também, na experimentação correta, há a casualização, isto é, a atribuição dos tratamentos às parcelas deve ser feita por sorteio para que não haja (des)favorecimento de nenhum tratamento.

Quando o ambiente com que se trabalha é razoavelmente uniforme, pode-se instalar o experimento apenas com o uso de repetição e casualização ou aleatorização. Isto ocorre, às vezes, em experimentos de laboratório ou de casas-de-vegetação ou de animais pequenos bem uniformes; estabelecendo o Delineamento Inteiramente Casualizado. Nos ensaios de campo ou com animais grandes, isso não ocorre, e então entra em ação outro princípio, o do controle local. Neste caso o material do experimento é repartido em porções bem uniformes, chamadas blocos. No caso dos blocos completos, o mais comum, cada bloco recebe todos os tratamentos, atribuídos por sorteio às parcelas do bloco e tem-se, então, o Delineamento em Blocos Casualizados (GOMES & GARCIA, 2002). Quando é necessário um controle local mais rígido, em duas direções perpendiculares entre si, como analogia a linhas e colunas de uma matriz, utiliza-se o Delineamento em Quadrado Latino.

No processamento analítico dos dados experimentais utiliza-se com frequência a técnica de análise de variância. Para tanto, adota-se um modelo estatístico, o qual assume várias premissas básicas a saber:

Aditividade: condição imposta pelo modelo, em que os diversos efeitos se somam. Esta premissa possibilita que os dados observados sejam sempre combinações lineares dos efeitos investigados.

Independência dos erros: a probabilidade do erro de uma observação qualquer assumir um dado valor não deve depender dos valores dos outros erros, o que define a independência deles.

Homogeneidade de variância: sinônimo de homocedasticidade, a homogeneidade dos erros assume que eles tenham todos a mesma variância. Essa premissa é fundamental para validar os testes F e de comparações de médias e o processo de estimação de componentes de variância.

Normalidade: os erros devem ser normalmente distribuídos. É importante para validar os testes de hipóteses. Já os testes de comparação de médias são robustos para

suportar a falta de normalidade dos dados (DIAS & BARROS, 2009).

Todo delineamento experimental está associado a um modelo estatístico. Considerando o delineamento, o esquema de análise, o modelo estatístico e satisfeitas as hipóteses básicas necessárias, pode-se passar à obtenção da análise de variância do experimento.

4.1 Delineamento Inteiramente Casualizado

Para o delineamento inteiramente casualizado tem-se o seguinte modelo estatístico:

$$Y_{ij} = \mu + \alpha_i + e_{ij},$$

em que $i = 1, 2, \dots, I$; $j = 1, 2, \dots, J$; Y_{ij} é a variável-resposta medida na parcela que recebeu o tratamento i na repetição j ; μ é a constante comum a todas as observações; α_i é o efeito do tratamento i ; e_{ij} é o efeito dos fatores não controlados na parcela Y_{ij} . Admite-se que $e_{ij} \sim N(0, \sigma_e^2)$.

Para melhor visualização do esquema de casualização do experimento, a seguir pode ser observado o *croquis* de um experimento em DIC:

α_1		
		α_1
α_2		

Figura 1: Ilustração de um experimento em DIC com seus tratamentos $\alpha_1, \alpha_2, \dots, \alpha_I$.

Considerando um experimento inteiramente casualizado com I tratamentos e J repetições, a soma de quadrados total (SQ_T) corresponde à soma de quadrados dos desvios de todos os dados em relação à média:

$$SQ_T = \sum_{i=1}^I \sum_{j=1}^J Y_{ij}^2 - Co, \quad (1)$$

em que Co é denominada *correção*, e é dada por:

$$Co = \frac{\left(\sum_{i=1}^I \sum_{j=1}^J Y_{ij} \right)^2}{IJ}. \quad (2)$$

A soma de quadrados de tratamentos (SQ_{Tr}) corresponde à soma dos quadrados dos efeitos totais de todos os tratamentos e, como em cada parcela ocorre o efeito de um tratamento, pode-se escrever:

$$SQ_{Tr} = \frac{\sum_{i=1}^I T_i^2}{J} - Co \quad (3)$$

em que T_i é o total dos tratamentos (BANZATTO & KRONKA, 2006).

Resta agora o cálculo da soma de quadrados devida aos efeitos dos fatores não controlados ou devido ao acaso, isto é, falta calcular a soma de quadrados do resíduo (SQ_R):

$$SQ_R = \sum_{i=1}^I \sum_{j=1}^J Y_{ij}^2 - Co - \left(\frac{\sum_{i=1}^I T_i^2}{J} - Co \right),$$

ou, de forma equivalente,

$$SQ_R = SQ_T - SQ_{Tr}.$$

Na análise de variância de um DIC, como previamente detalhado, tem-se a fonte de variação total separada em fonte de variação devida a tratamentos (*Trat*) e devida ao *Resíduo*, que se encontram na tabela da análise de variância (ANAVA):

Tabela 1: Tabela da ANAVA para um experimento em DIC.

FV	GL	SQ	QM	F_c
Trat	$I - 1$	SQ_{Tr}	$\frac{SQ_{Tr}}{gl_{Tr}}$	$\frac{QM_{Tr}}{QM_R}$
Resíduo	$I(J - 1)$	SQ_R	$\frac{SQ_R}{gl_R}$	
Total	$IJ - 1$	SQ_T	$\frac{SQ_T}{gl_T}$	

Esta tabela informa as fontes de variação (FV), os graus de liberdade (GL), as somas de quadrados (SQ), os quadrados médios (QM), e o F calculado (F_c) para cada fonte de variação.

O teste F compara o F_c com um F tabelado (F_t), que é função da significância estabelecida (α) e dos graus de liberdade do tratamento e do resíduo, respectivamente, ν_1 e ν_2 .

4.2 Delineamento em Blocos Casualizados

No delineamento em blocos casualizados, controla-se um fator da variação que insere heterogeneidade no experimento. Essa causa de variação é denominada de *bloco*, e o modelo estatístico deve conter o efeito desse controle local. Logo, para o delineamento em blocos casualizados, o modelo estatístico é:

$$Y_{ij} = \mu + \alpha_i + \lambda_j + e_{ij},$$

em que $i = 1, 2, \dots, I$; $j = 1, 2, \dots, J$; Y_{ij} é a variável-resposta medida na parcela que recebeu o tratamento i no bloco j ; μ é a constante comum a todas as observações; α_i é o efeito do tratamento i ; λ_j é o efeito do bloco j ; e_{ij} é o efeito dos fatores não controlados na parcela Y_{ij} . Admite-se que $e_{ij} \sim N(0, \sigma_e^2)$.

Para melhor visualização do esquema de casualização do experimento, a seguir pode ser observado o *croquis* de um experimento em DBC:




Figura 2: Ilustração de um experimento em DBC com seus tratamentos $\alpha_1, \dots, \alpha_I$ e blocos $\lambda_1, \dots, \lambda_J$.

Considerando um experimento em blocos casualizados com I tratamentos e J blocos, deve-se incluir a soma de quadrados dos blocos (SQ_B):

$$SQ_B = \frac{\sum_{j=1}^J B_j^2}{I} - Co$$

em que B_j é o total dos blocos (BANZATTO & KRONKA, 2006). Esta soma de quadrados

deve ser considerada na soma de quadrados do resíduo (SQ_R), que fica reescrita como:

$$SQ_R = \sum_{i=1}^I \sum_{j=1}^J Y_{ij}^2 - Co - \left(\frac{\sum_{i=1}^I T_i^2}{J} - Co + \frac{\sum_{j=1}^J B_j^2}{I} - Co \right),$$

ou, simplesmente,

$$SQ_R = SQ_T - (SQ_{Tr} + SQ_B).$$

Na análise de variância de um DBC, como citado acima, inclui-se a fonte de variação *bloco*, inserindo uma nova linha na tabela da ANAVA:

Tabela 2: Tabela da ANAVA para um experimento em DBC.

FV	GL	SQ	QM	F_c
Trat	$I - 1$	SQ_{Tr}	$\frac{SQ_{Tr}}{gl_{Tr}}$	$\frac{QM_{Tr}}{QM_R}$
Bloco	$J - 1$	SQ_B	$\frac{SQ_B}{gl_B}$	$\frac{QM_B}{QM_R}$
Resíduo	$(I - 1)(J - 1)$	SQ_R	$\frac{SQ_R}{gl_R}$	
Total	$IJ - 1$	SQ_T	$\frac{SQ_T}{gl_T}$	

Analogamente é feito o teste F para a fonte de variação *Bloco*, com o F_t em função da significância (α) e dos graus de liberdade do bloco e do resíduo, respectivamente, ν_1 e ν_2 .

4.3 Delineamento em Quadrado Latino

No delineamento em quadrado latino, controlam-se duas causas da variação não desejadas, ou seja, dois tipos de bloco chamados comumente de *linhas* e as *colunas*, de modo que o modelo estatístico deve espelhar esse controle. Desta forma, para o delineamento em quadrado latino, o modelo estatístico é dado por:

$$Y_{ijk} = \mu + \alpha_i + \lambda_j + \delta_k + e_{ijk},$$

em que $i, j, k \in 1, 2, \dots, I$; Y_{ijk} é a variável-resposta medida na parcela que recebeu o tratamento i na linha j e na coluna k ; μ é a constante comum a todas as observações; α_i é o efeito do tratamento i ; λ_j é o efeito da linha j ; δ_k é o efeito da coluna k ; e_{ijk} é o efeito dos fatores não controlados na parcela Y_{ijk} . Admite-se que $e_{ij} \sim N(0, \sigma_e^2)$.

Para melhor visualização do esquema de casualização do experimento, a seguir pode ser observado o *croquis* de um experimento em DQL:

α_1		α_I	
	α_I	α_1	
α_I			α_1
	α_1		α_I

Figura 3: Ilustração de um experimento em DQL com seus tratamentos $\alpha_1, \dots, \alpha_I$.

Considerando agora um experimento em quadrado latino com l linhas e c colunas, deve-se incluir a soma de quadrados das linhas (SQ_L) e colunas (SQ_C):

$$SQ_L = \frac{\sum_{j=1}^I L_j^2}{I} - Co$$

$$SQ_C = \frac{\sum_{k=1}^I C_k^2}{I} - Co$$

em que L_j é o total das linhas e C_k é o total das colunas (GOMES, 2009). Estas somas

de quadrados devem ser consideradas na soma de quadrados do resíduo (SQ_R):

$$SQ_R = \sum_{i,j,k=1}^I Y_{ijk}^2 - Co - \left(\frac{\sum_{i=1}^I T_i^2}{I} - Co + \frac{\sum_{j=1}^I L_j^2}{I} - Co + \frac{\sum_{k=1}^I C_j^2}{I} - Co \right),$$

ou, simplesmente,

$$SQ_R = SQ_T - (SQ_{Tr} + SQ_L + SQ_C).$$

Na análise de variância de um DQL, não apenas um bloco, mas dois (*linhas e colunas*) devem ser considerados e a tabela da ANAVA se torna:

Tabela 3: Tabela da ANAVA para um experimento em DQL.

FV	GL	SQ	QM	F_c
Trat	$I - 1$	SQ_{Tr}	$\frac{SQ_{Tr}}{gl_{Tr}}$	$\frac{QM_{Tr}}{QM_R}$
Linha	$I - 1$	SQ_L	$\frac{SQ_L}{gl_L}$	$\frac{QM_L}{QM_R}$
Coluna	$I - 1$	SQ_C	$\frac{SQ_C}{gl_C}$	$\frac{QM_C}{QM_R}$
Resíduo	$(I - 1)(I - 2)$	SQ_R	$\frac{SQ_R}{gl_R}$	
Total	$I^2 - 1$	SQ_T	$\frac{SQ_T}{gl_T}$	

É importante ressaltar que o número de tratamentos, linhas e colunas, neste delineamento, devem ser necessariamente iguais e, portanto, o grau de liberdade destas fontes de variação é o mesmo ($I - 1$).

O teste F agora pode ser calculado também para as fontes de variação *Linha* e *Coluna*, e, desta forma, o F_t fica em função da significância estabelecida (α), do grau de liberdade das linhas para o F_t da *Linha* (ν_1), do grau de liberdade das colunas para o F_t da *Coluna* (ν_1) e do grau de liberdade do resíduo (ν_2).

4.4 Experimentos em esquema fatorial

Arranjos fatoriais são apropriados para casos em que se pretende avaliar dois ou mais fatores, simultaneamente. Este tipo de experimento envolve combinações entre todos os níveis dos vários fatores, razão pela qual é denominado fatorial completo, ou apenas parte das combinações, caracterizando um fatorial incompleto, e podem ser aplicados à quaisquer dos delineamentos abordados neste trabalho (DIC, DBC e DQL).

O modelo estatístico para um experimento em esquema de fatorial duplo (2 fatores), conduzido em DIC, é dado por:

$$Y_{ijk} = \mu + \alpha_i + \beta_j + (\alpha\beta)_{ij} + e_{ijk},$$

em que $i = 1, 2, \dots, a$; $j = 1, 2, \dots, b$; $k = 1, 2, \dots, J$; Y_{ijk} é a variável-resposta medida na parcela que recebeu o nível i do fator α , o nível j do fator β , na repetição k ; μ é a constante comum a todas as observações; α_i é o efeito do i -ésimo nível do fator α ; β_j é o efeito do j -ésimo nível do fator β ; $(\alpha\beta)_{ij}$ é o efeito da interação entre o i -ésimo nível do fator α e o j -ésimo nível do fator β ; e_{ijk} é o efeito dos fatores não controlados na parcela Y_{ijk} .

Os tratamentos deste experimento são obtidos pela combinação dos níveis do fator α com os níveis do fator β (axb), como pode ser observado no esquema de casualização do experimento, mostrado a seguir:

$(\alpha_1\beta_b)_J$				$(\alpha_1\beta_1)_J$
		$(\alpha_a\beta_b)_J$		
$(\alpha_1\beta_1)_1$				$(\alpha_a\beta_1)_1$
			$(\alpha_a\beta_b)_1$	
$(\alpha_a\beta_1)_J$		$(\alpha_1\beta_b)_1$		

Figura 4: Ilustração de um experimento em esquema de fatorial duplo em DIC, com seus tratamentos obtidos das combinações dos níveis do fator α com os níveis do fator β .

Considerando esta estrutura fatorial dos tratamentos, a soma de quadrados para tratamentos pode ser decomposta nas somas de quadrados relativas ao efeito dos fatores e suas interações. Assim as Fontes de Variação passam a ser todos os fatores e todas as

possíveis interações entre eles. Admitindo um experimento com dois fatores α_i e β_j , sendo $i : 1, 2, \dots, a$ e $j : 1, 2, \dots, b$, tem-se a soma de quadrados do fator α (SQ_α), a soma de quadrados do fator β (SQ_β) e a soma de quadrados da interação ($\alpha\beta$), $SQ_{\alpha\beta}$:

$$SQ_\alpha = \frac{\sum_{i=1}^a A_i^2}{Jb} - Co, \quad (4)$$

em que A_i é o total do i -ésimo nível do fator α , ao longo das repetições e dos níveis de β .

$$SQ_\beta = \frac{\sum_{j=1}^b B_j^2}{Ja} - Co$$

em que B_j é o total do j -ésimo nível do fator β , ao longo das repetições e dos níveis de α (BANZATTO & KRONKA, 2006).

$$SQ_{\alpha\beta} = SQ_{Tr} - (SQ_\alpha + SQ_\beta)$$

Como a soma de quadrados do resíduo é calculada pela diferença entre a soma de quadrados total e a soma de quadrados de tratamentos, em esquemas fatoriais tem-se:

$$SQ_R = SQ_T - (SQ_\alpha + SQ_\beta + SQ_{\alpha\beta}).$$

Na análise de variância de um experimento em esquema de fatorial duplo em DIC, tem-se como fontes de variação: os fatores α e β e a interação entre eles ($\alpha * \beta$), como pode ser observado na tabela da ANAVA a seguir:

Tabela 4: Tabela da ANAVA para um experimento em fatorial duplo em DIC.

FV	GL	SQ	QM	F_c
α	$a - 1$	SQ_α	$\frac{SQ_\alpha}{gl_\alpha}$	$\frac{QM_\alpha}{QM_R}$
β	$b - 1$	SQ_β	$\frac{SQ_\beta}{gl_\beta}$	$\frac{QM_\beta}{QM_R}$
$\alpha * \beta$	$(a - 1)(b - 1)$	$SQ_{\alpha\beta}$	$\frac{SQ_{\alpha\beta}}{gl_{\alpha\beta}}$	$\frac{QM_{\alpha\beta}}{QM_R}$
Resíduo	$ab(J - 1)$	SQ_R	$\frac{SQ_R}{gl_R}$	
Total	$abJ - 1$	SQ_T	$\frac{SQ_T}{gl_T}$	

O teste F para esquemas fatoriais pode ser realizado para cada fator em estudo e para a interação entre eles, sendo assim, o F_t é função da significância estabelecida (α), dos graus de liberdade do fator para o F_t de cada fator (ν_1), dos graus de liberdade da interação para o F_t da interação (ν_1) e dos graus de liberdade do resíduo (ν_2).

Quando um experimento em esquema de fatorial duplo é conduzido em DBC, seu

modelo estatístico se torna:

$$Y_{ijk} = \mu + \lambda_k + \alpha_i + \beta_j + (\alpha\beta)_{ij} + e_{ijk},$$

em que $i = 1, 2, \dots, a$; $j = 1, 2, \dots, b$; $k = 1, 2, \dots, J$; Y_{ijk} é a variável-resposta medida na parcela que recebeu o nível i do fator α , o nível j do fator β , no bloco k ; μ é a constante comum a todas as observações; λ_k é o efeito do bloco k ; α_i é o efeito do i -ésimo nível do fator α ; β_j é o efeito do j -ésimo nível do fator β ; $(\alpha\beta)_{ij}$ é o efeito da interação entre o i -ésimo nível do fator α e o j -ésimo nível do fator β ; e_{ijk} é o efeito dos fatores não controlados na parcela Y_{ijk} .

Para melhor visualização do esquema de casualização do experimento, a seguir pode ser observado o *croquis* de um experimento em fatorial duplo, conduzido em DBC:

λ_1	$\alpha_1\beta_1$		$\alpha_a\beta_b$
λ_2	$\alpha_a\beta_b$	$\alpha_1\beta_1$	
\vdots			
λ_J		$\alpha_a\beta_b$	$\alpha_1\beta_1$

Figura 5: Ilustração de um experimento em esquema de fatorial duplo em DBC, com seus tratamentos obtidos das combinações dos níveis do fator α com os níveis do fator β , nos blocos $\lambda_1, \lambda_2, \dots, \lambda_J$.

Desta maneira, a fonte de variação *Bloco* deve ser inserida na tabela da ANAVA, que pode ser observado abaixo:

Já para um experimento em esquema de fatorial triplo (3 fatores), conduzido em DIC, tem-se o seguinte modelo estatístico:

$$Y_{ijkl} = \mu + \alpha_i + \beta_j + \gamma_k + (\alpha\beta)_{ij} + (\alpha\gamma)_{ik} + (\beta\gamma)_{jk} + (\alpha\beta\gamma)_{ijk} + e_{ijkl},$$

em que $i = 1, 2, \dots, a$; $j = 1, 2, \dots, b$; $k = 1, 2, \dots, c$; $l = 1, 2, \dots, J$; Y_{ijkl} é a variável-resposta medida na parcela que recebeu o nível i do fator α , o nível j do fator β , o nível k do fator γ , na repetição l ; μ é a constante comum a todas as observações; α_i é o efeito do i -ésimo nível do fator α ; β_j é o efeito do j -ésimo nível do fator β ; γ_k é o efeito do k -ésimo nível do fator γ ; $(\alpha\beta)_{ij}$ é o efeito da interação entre o i -ésimo nível do fator α e

Tabela 5: Tabela da ANAVA para um experimento em fatorial duplo em DBC.

FV	GL	SQ	QM	F_c
Bloco	$J - 1$	SQ_B	$\frac{SQ_B}{gl_B}$	$\frac{QM_B}{QM_R}$
α	$a - 1$	SQ_α	$\frac{SQ_\alpha}{gl_\alpha}$	$\frac{QM_\alpha}{QM_R}$
β	$b - 1$	SQ_β	$\frac{SQ_\beta}{gl_\beta}$	$\frac{QM_\beta}{QM_R}$
$\alpha * \beta$	$(a - 1)(b - 1)$	$SQ_{\alpha\beta}$	$\frac{SQ_{\alpha\beta}}{gl_{\alpha\beta}}$	$\frac{QM_{\alpha\beta}}{QM_R}$
Resíduo	$(ab - 1)(J - 1)$	SQ_R	$\frac{SQ_R}{gl_R}$	
Total	$abJ - 1$	SQ_T	$\frac{SQ_T}{gl_T}$	

o j -ésimo nível do fator β ; $(\alpha\gamma)_{ik}$ é o efeito da interação entre o i -ésimo nível do fator α e o k -ésimo nível do fator γ ; $(\beta\gamma)_{jk}$ é o efeito da interação entre o j -ésimo nível do fator β e o k -ésimo nível do fator γ ; $(\alpha\beta\gamma)_{ijk}$ é o efeito da interação entre o i -ésimo nível do fator α , o j -ésimo nível do fator β e o k -ésimo nível do fator γ ; e_{ijkl} é o efeito dos fatores não controlados na parcela Y_{ijkl} .

Os tratamentos deste experimento são obtidos pela combinação dos níveis do fator α com os níveis do fator β e os níveis do fator γ (axbxc), como pode ser observado no esquema de casualização do experimento, mostrado a seguir:

				$(\alpha_1\beta_1\gamma_1)_J$
		$(\alpha_2\beta_b\gamma_c)_J$		
$(\alpha_1\beta_1\gamma_1)_1$				
			$(\alpha_2\beta_b\gamma_c)_1$	

Figura 6: Ilustração de um experimento em esquema de fatorial triplo em DIC, com seus tratamentos obtidos das combinações dos níveis do fator α com os níveis do fator β e os níveis do fator γ .

Considerando agora a estrutura do fatorial triplo, com seus 3 fatores α_i , β_j e γ_k , sendo $i : 1, 2, \dots, a$, $j : 1, 2, \dots, b$ e $k : 1, 2, \dots, c$; a soma de quadrados dos tratamentos é decomposta na soma de quadrados de cada um dos 3 fatores (SQ_α , SQ_β e SQ_γ) e nas somas de quadrados das interações ($SQ_{\alpha\beta}$, $SQ_{\alpha\gamma}$, $SQ_{\beta\gamma}$ e $SQ_{\alpha\beta\gamma}$).

As somas de quadrados dos fatores α , β e γ ; podem ser calculadas pelas fórmulas a seguir:

$$SQ_{\alpha} = \frac{\sum_{i=1}^a A_i^2}{Jbc} - Co,$$

em que A_i representa o total do i -ésimo nível do fator α , ao longo das repetições, dos níveis de β e níveis de γ ;

$$SQ_{\beta} = \frac{\sum_{j=1}^b B_j^2}{Jac} - Co,$$

em que B_j representa o total do j -ésimo nível do fator β , ao longo das repetições, dos níveis de α e níveis de γ ;

$$SQ_{\gamma} = \frac{\sum_{k=1}^c C_k^2}{Jab} - Co,$$

em que C_k representa o total do k -ésimo nível do fator γ , ao longo das repetições, dos níveis de α e níveis de β (BANZATTO & KRONKA, 2006).

A soma de quadrados da interação $\alpha * \beta$ agora é obtida da diferença entre a soma de quadrados dos tratamentos resultantes de um fatorial duplo entre α e β , e as somas de quadrados desses fatores, conforme:

$$SQ_{\alpha\beta} = \frac{\sum_{i,j}^{a,b} AB_{ij}^2}{cJ} - Co - (SQ_{\alpha} + SQ_{\beta}),$$

em que AB_{ij} são os totais dos tratamentos gerados pela combinação fatorial do i -ésimo nível do fator α com o j -ésimo nível do fator β , ao longo das repetições e níveis de γ .

Analogamente, podem ser obtidas as somas de quadrados das interações $\alpha\gamma$ e $\beta\gamma$, a saber:

$$SQ_{\alpha\gamma} = \frac{\sum_{i,k}^{a,c} AC_{ik}^2}{bJ} - Co - (SQ_{\alpha} + SQ_{\gamma}),$$

em que AC_{ik} são os totais dos tratamentos gerados pela combinação fatorial do i -ésimo nível do fator α com o k -ésimo nível do fator γ , ao longo das repetições e níveis de β .

$$SQ_{\beta\gamma} = \frac{\sum_{j,k}^{b,c} BC_{jk}^2}{aJ} - Co - (SQ_{\beta} + SQ_{\gamma}),$$

em que BC_{jk} são os totais dos tratamentos gerados pela combinação fatorial do j -ésimo nível do fator β com o k -ésimo nível do fator γ , ao longo das repetições e níveis de α .

A interação tripla $\alpha * \beta * \gamma$ também pode ser obtida por diferença. Ela é a diferença entre a soma de quadrados dos tratamentos obtidos pela combinação fatorial dos fatores α , β e γ e os efeitos simples e interações duplas, conforme:

$$SQ_{\alpha\beta\gamma} = \frac{\sum_{i,j,k}^{a,b,c} ABC_{ijk}^2}{J} - Co - (SQ_{\alpha} + SQ_{\beta} + SQ_{\gamma} + SQ_{\alpha\beta} + SQ_{\alpha\gamma} + SQ_{\beta\gamma}),$$

sendo ABC os totais dos tratamentos obtidos pela combinação fatorial do i -ésimo nível do fator α com o j -ésimo nível do fator β e o k -ésimo nível do fator γ , ao longo das repetições.

Desta forma, a tabela da ANAVA para um experimento em esquema de fatorial triplo, em DIC, pode ser observado abaixo:

Tabela 6: Tabela da ANAVA para um experimento em fatorial triplo em DIC.

FV	GL	SQ	QM	F_c
α	$a - 1$	SQ_{α}	$\frac{SQ_{\alpha}}{gl_{\alpha}}$	$\frac{QM_{\alpha}}{QM_R}$
β	$b - 1$	SQ_{β}	$\frac{SQ_{\beta}}{gl_{\beta}}$	$\frac{QM_{\beta}}{QM_R}$
γ	$c - 1$	SQ_{γ}	$\frac{SQ_{\gamma}}{gl_{\gamma}}$	$\frac{QM_{\gamma}}{QM_R}$
$\alpha * \beta$	$(a - 1)(b - 1)$	$SQ_{\alpha\beta}$	$\frac{SQ_{\alpha\beta}}{gl_{\alpha\beta}}$	$\frac{QM_{\alpha\beta}}{QM_R}$
$\alpha * \gamma$	$(a - 1)(c - 1)$	$SQ_{\alpha\gamma}$	$\frac{SQ_{\alpha\gamma}}{gl_{\alpha\gamma}}$	$\frac{QM_{\alpha\gamma}}{QM_R}$
$\beta * \gamma$	$(b - 1)(c - 1)$	$SQ_{\beta\gamma}$	$\frac{SQ_{\beta\gamma}}{gl_{\beta\gamma}}$	$\frac{QM_{\beta\gamma}}{QM_R}$
$\alpha * \beta * \gamma$	$(a - 1)(b - 1)(c - 1)$	$SQ_{\alpha\beta\gamma}$	$\frac{SQ_{\alpha\beta\gamma}}{gl_{\alpha\beta\gamma}}$	$\frac{QM_{\alpha\beta\gamma}}{QM_R}$
Resíduo	$abc(J - 1)$	SQ_R	$\frac{SQ_R}{gl_R}$	
Total	$abcJ - 1$	SQ_T	$\frac{SQ_T}{gl_T}$	

Quando um experimento em esquema de fatorial triplo é conduzido em DBC, seu modelo estatístico se torna:

$$Y_{ijkl} = \mu + \lambda_l + \alpha_i + \beta_j + \gamma_k + (\alpha\beta)_{ij} + (\alpha\gamma)_{ik} + (\beta\gamma)_{jk} + (\alpha\beta\gamma)_{ijk} + e_{ijkl},$$

em que $i = 1, 2, \dots, a$; $j = 1, 2, \dots, b$; $k = 1, 2, \dots, c$; $l = 1, 2, \dots, J$; Y_{ijkl} é a variável-resposta medida na parcela que recebeu o nível i do fator α , o nível j do fator β , o nível k do fator γ , no bloco l ; μ é a constante comum a todas as observações; λ_l é o efeito do bloco l ; α_i é o efeito do i -ésimo nível do fator α ; β_j é o efeito do j -ésimo nível do fator β ; γ_k é o efeito do k -ésimo nível do fator γ ; $(\alpha\beta)_{ij}$ é o efeito da interação entre o i -ésimo nível do fator α e o j -ésimo nível do fator β ; $(\alpha\gamma)_{ik}$ é o efeito da interação entre o i -ésimo nível do fator α e o k -ésimo nível do fator γ ; $(\beta\gamma)_{jk}$ é o efeito da interação entre o j -ésimo nível do fator β e o k -ésimo nível do fator γ ; $(\alpha\beta\gamma)_{ijk}$ é o efeito da interação entre o i -ésimo nível do fator α , o j -ésimo nível do fator β e o k -ésimo nível do fator γ ; e_{ijkl} é o efeito dos fatores não controlados na parcela Y_{ijkl} .

Para melhor visualização do esquema de casualização do experimento, a seguir pode ser observado o *croquis* de um experimento em fatorial triplo, conduzido em DBC:

λ_1	$\alpha_1\beta_1\gamma_1$	$\alpha_a\beta_b\gamma_c$	
λ_2	$\alpha_a\beta_b\gamma_c$		$\alpha_1\beta_1\gamma_1$
\vdots			
λ_J		$\alpha_1\beta_1\gamma_1$	$\alpha_a\beta_b\gamma_c$

Figura 7: Ilustração de um experimento em esquema de fatorial triplo em DBC, com seus tratamentos obtidos das combinações dos níveis do fator α com os níveis do fator β e os níveis do fator γ , nos blocos $\lambda_1, \lambda_2, \dots, \lambda_J$.

A tabela da ANAVA de um experimento em fatorial triplo, conduzido em DBC, pode ser observado a seguir:

Tabela 7: Tabela da ANAVA para um experimento em fatorial triplo em DBC.

FV	GL	SQ	QM	F_c
Bloco	$J - 1$	SQ_B	$\frac{SQ_B}{gl_B}$	$\frac{QM_B}{QM_R}$
α	$a - 1$	SQ_α	$\frac{SQ_\alpha}{gl_\alpha}$	$\frac{QM_\alpha}{QM_R}$
β	$b - 1$	SQ_β	$\frac{SQ_\beta}{gl_\beta}$	$\frac{QM_\beta}{QM_R}$
γ	$c - 1$	SQ_γ	$\frac{SQ_\gamma}{gl_\gamma}$	$\frac{QM_\gamma}{QM_R}$
$\alpha * \beta$	$(a - 1)(b - 1)$	$SQ_{\alpha\beta}$	$\frac{SQ_{\alpha\beta}}{gl_{\alpha\beta}}$	$\frac{QM_{\alpha\beta}}{QM_R}$
$\alpha * \gamma$	$(a - 1)(c - 1)$	$SQ_{\alpha\gamma}$	$\frac{SQ_{\alpha\gamma}}{gl_{\alpha\gamma}}$	$\frac{QM_{\alpha\gamma}}{QM_R}$
$\beta * \gamma$	$(b - 1)(c - 1)$	$SQ_{\beta\gamma}$	$\frac{SQ_{\beta\gamma}}{gl_{\beta\gamma}}$	$\frac{QM_{\beta\gamma}}{QM_R}$
$\alpha * \beta * \gamma$	$(a - 1)(b - 1)(c - 1)$	$SQ_{\alpha\beta\gamma}$	$\frac{SQ_{\alpha\beta\gamma}}{gl_{\alpha\beta\gamma}}$	$\frac{QM_{\alpha\beta\gamma}}{QM_R}$
Resíduo	$(abc - 1)(J - 1)$	SQ_R	$\frac{SQ_R}{gl_R}$	
Total	$abcJ - 1$	SQ_T	$\frac{SQ_T}{gl_T}$	

4.5 Experimentos em esquema de parcelas subdivididas

Um tipo particular (especial) de esquema fatorial de análise é o esquema em parcelas subdivididas. Esse esquema se faz necessário quando um dos dois fatores em questão (considerando-se um fatorial duplo) tem seus níveis auto-correlacionados, ou ainda, quando se deseja mais precisão na inferência sobre um dos fatores.

Considere que, no esquema abordado neste tópico, o fator α foi atribuído às parcelas, e o fator β foi atribuído às subparcelas. O modelo estatístico para um experimento em esquema de parcelas subdivididas, conduzido em DIC, é dado por:

$$Y_{ijk} = \mu + \alpha_i + e_A + \beta_j + (\alpha\beta)_{ij} + e_B,$$

em que $i = 1, 2, \dots, a$; $j = 1, 2, \dots, b$; $k = 1, 2, \dots, J$; Y_{ijk} é a variável-resposta medida na parcela que recebeu o nível i do fator α , o nível j do fator β , na repetição k ; μ é a constante comum a todas as observações; α_i é o efeito do i -ésimo nível do fator α ; e_A é o erro associado às parcelas; β_j é o efeito do j -ésimo nível do fator β ; $(\alpha\beta)_{ij}$ é o efeito da interação entre os fatores α e β ; e_B é o erro aleatório associado às subparcelas.

Para melhor visualização do esquema de casualização do experimento, a seguir pode ser observado o *croquis* de um experimento em esquema de parcelas subdivididas, conduzido em DIC:

α_1				α_1
β_1 β_2 ... β_b				β_1 β_2 ... β_b
		α_a		
		β_1 β_2 ... β_b		
α_1				α_a
β_1 β_2 ... β_b				β_1 β_2 ... β_b
			α_a	
			β_1 β_2 ... β_b	
α_a		α_1		
β_1 β_2 ... β_b		β_1 β_2 ... β_b		

Figura 8: Ilustração de um experimento em esquema de parcelas subdivididas em DIC, com seus tratamentos obtidos das combinações dos níveis do fator α (fator alocado nas parcelas) com os níveis do fator β (fator alocado nas subparcelas).

Em um experimento em parcelas subdivididas (conduzido em DIC ou DBC), a soma de quadrados de subparcela pode ser denominada soma de quadrados total (SQ_T), que é

dada pela equação (1).

Uma das características mais típicas dos ensaios em parcelas subdivididas é a partição do erro experimental em duas fontes de variação, comumente chamados de *resíduo a* e *resíduo b*.

Para a obtenção das somas quadrados do resíduo *a* deve-se calcular, primeiramente a soma de quadrados de tratamentos (SQ_{Tr}) e a soma de quadrados de parcela (SQ_{par}). Para isso, é útil construir uma tabela auxiliar com os totais de cada tratamento, conforme o esquema:

Tabela 8: Tabela Auxiliar para experimentos em parcelas subdivididas, em DIC.

	Fator β				
Fator α	1	2	...	b	Total
1	T_{11}	T_{12}	...	T_{1b}	A_1
2	T_{21}	T_{22}	...	T_{2b}	A_2
\vdots	\vdots	\vdots	\vdots	\vdots	\vdots
a	T_{a1}	T_{a2}	...	T_{ab}	A_a
Total	B_1	B_2	...	B_b	AB

em que AB é o total das combinações entre os fatores α e β .

Dessa forma, pode-se determinar facilmente as somas de quadrados de tratamentos (SQ_{Tr}), de parcelas (SQ_{par}) e do resíduo *a* (SQ_{Ra}), que são dadas por:

$$SQ_{Tr} = \sum_{i,j}^{a,b} \frac{AB_{ij}^2}{J} - Co,$$

em que AB_{ij} são os totais dos tratamentos gerados pela combinação fatorial do *i*-ésimo nível do fator α com o *j*-ésimo nível do fator β , ao longo das repetições *J*;

$$SQ_{par} = \sum_{i,k}^{a,J} \frac{A_{ik}^2}{b} - Co,$$

em que A_{ik} é o total do *i*-ésimo nível do fator α na *k*-ésima repetição *J*, ao longo dos níveis do fator β ;

$$SQ_{Ra} = SQ_{par} - SQ_{\alpha},$$

em que SQ_{α} já foi definido pela equação (4) (BANZATTO & KRONKA, 2006).

Para o cálculo das somas de quadrados da interação $\alpha * \beta$ e do resíduo *b*, a tabela anterior também é útil. Elas são dadas por:

$$SQ_{\alpha\beta} = SQ_{Tr} - (SQ_{par} + SQ_{\beta})$$

$$SQ_{Rb} = SQ_T - (SQ_{par} + SQ_{\beta} + SQ_{\alpha\beta}).$$

Na análise de variância de um experimento em esquema de parcelas subdivididas em DIC, tem-se como fontes de variação na parcela: o fator α e o resíduo da parcela (*resíduo a*); já na subparcela encontram-se: o fator β , a interação entre os fatores ($\alpha * \beta$) e o resíduo da subparcela (*resíduo b*), como pode ser observado na tabela da ANAVA a seguir:

Tabela 9: Tabela da ANAVA para um experimento em parcelas subdivididas em DIC.

FV	GL	SQ	QM	F_c
α	$a - 1$	SQ_α	$\frac{SQ_\alpha}{gl_\alpha}$	$\frac{QM_\alpha}{QM_{Ra}}$
Resíduo a	$a(J - 1)$	SQ_{Ra}	$\frac{SQ_{Ra}}{gl_{Ra}}$	
Parcela	$aJ - 1$	SQ_{par}	$\frac{SQ_{par}}{gl_{par}}$	
β	$b - 1$	SQ_β	$\frac{SQ_\beta}{gl_\beta}$	$\frac{QM_\beta}{QM_{Rb}}$
$\alpha * \beta$	$(a - 1)(b - 1)$	$SQ_{\alpha\beta}$	$\frac{SQ_{\alpha\beta}}{gl_{\alpha\beta}}$	$\frac{QM_{\alpha\beta}}{QM_{Rb}}$
Resíduo b	$a(b - 1)(J - 1)$	SQ_{Rb}	$\frac{SQ_{Rb}}{gl_{Rb}}$	
Total	$abJ - 1$	SQ_T	$\frac{SQ_T}{gl_T}$	

O teste F para experimentos em parcelas subdivididas pode ser realizado para cada fator em estudo e para a interação entre eles, contudo deve-se tomar o cuidado de utilizar o *Resíduo a* para os fatores que estiverem na parcela e o *Resíduo b* para os da subparcela. Neste caso, o F_t do fator α (fator que está na parcela) é função da significância estabelecida (α), dos graus de liberdade deste fator (ν_1) e dos graus de liberdade do *Resíduo a* (ν_2); para os fatores que estão na subparcela (fator β e interação $\alpha * \beta$) o F_t é função da significância estabelecida (α), dos graus de liberdade do fator ou da interação (ν_1), respectivamente, e dos graus de liberdade do *Resíduo b* (ν_2).

Quando o experimento em esquema de parcelas subdivididas estiver em DBC, a fonte de variação *Bloco* deve ser inserida na parcela e, desta forma, o modelo estatístico se torna:

$$Y_{ijk} = \mu + \alpha_i + \lambda_k + e_A + \beta_j + (\alpha\beta)_{ij} + e_B,$$

em que $i = 1, 2, \dots, a$; $j = 1, 2, \dots, b$; $k = 1, 2, \dots, J$; Y_{ijk} é a variável-resposta medida na parcela que recebeu o nível i do fator α , o nível j do fator β , na repetição k ; μ é a constante comum a todas as observações; α_i é o efeito do i -ésimo nível do fator α ; λ_k é o efeito do bloco k ; e_A é o erro associado às parcelas; β_j é o efeito do j -ésimo nível do fator β ; $(\alpha\beta)_{ij}$ é o efeito da interação entre os fatores α e β ; e_B é o erro aleatório associado às subparcelas.

Para melhor visualização do esquema de casualização do experimento, a seguir pode ser observado o *croquis* de um experimento em esquema de parcelas subdivididas, conduzido em DBC:

λ_1	α_a								α_1			
	β_1	β_2	...	β_b					β_1	β_2	...	β_b
λ_2					α_a				α_1			
					β_1	β_2	...	β_b	β_1	β_2	...	β_b
\vdots												
λ_J					α_1							
					β_1	β_2	...	β_b				

Figura 9: Ilustração de um experimento em esquema de parcelas subdivididas em DBC, com seus tratamentos obtidos das combinações dos níveis do fator α (fator alocado nas parcelas) com os níveis do fator β (fator alocado nas subparcelas), nos blocos $\lambda_1, \lambda_2, \dots, \lambda_J$.

A tabela da ANAVA também é modificada, recebendo mais uma linha na parcela, o que altera o *resíduo a*:

Tabela 10: Tabela da ANAVA para um experimento em parcelas subdivididas em DBC.

FV	GL	SQ	QM	F_c
α	$a - 1$	SQ_α	$\frac{SQ_\alpha}{gl_\alpha}$	$\frac{QM_\alpha}{QM_{R_a}}$
Bloco	$J - 1$	SQ_B	$\frac{SQ_B}{gl_B}$	$\frac{QM_B}{QM_{R_a}}$
Resíduo a	$(a - 1)(J - 1)$	SQ_{R_a}	$\frac{SQ_{R_a}}{gl_{R_a}}$	
Parcela	$aJ - 1$	SQ_{par}	$\frac{SQ_{par}}{gl_{par}}$	
β	$b - 1$	SQ_β	$\frac{SQ_\beta}{gl_\beta}$	$\frac{QM_\beta}{QM_{R_b}}$
$\alpha * \beta$	$(a - 1)(b - 1)$	$SQ_{\alpha\beta}$	$\frac{SQ_{\alpha\beta}}{gl_{\alpha\beta}}$	$\frac{QM_{\alpha\beta}}{QM_{R_b}}$
Resíduo b	$a(b - 1)(J - 1)$	SQ_{R_b}	$\frac{SQ_{R_b}}{gl_{R_b}}$	
Total	$abJ - 1$	SQ_T	$\frac{SQ_T}{gl_T}$	

4.6 Tratamento Adicional

No planejamento de experimentos fatoriais e de experimento em esquema de parcelas subdivididas é frequentemente desejável incluir alguns tratamentos extras, fora do esquema fatorial usual, chamados de tratamento adicional. Contudo, existem casos em que é interessante contrastar alguns tratamentos extras com tratamentos de delineamentos simples, como experimentos em DIC, DBC ou DQL, por exemplo.

Considerando um fatorial duplo com um tratamento adicional em DIC, tem-se o seguinte modelo estatístico:

$$Y = \begin{cases} \mu + \alpha_i + \beta_j + (\alpha\beta)_{ij} + e_{ijk}, & \text{se } Y = Y_{ijk} \in \text{fatorial} \\ \mu + \tau + e_k, & \text{se } Y = Y_k \notin \text{fatorial} \end{cases}$$

em que, além dos efeitos já explicados na seção (4.4), τ é o contraste entre o fatorial duplo e o tratamento adicional.

Para melhor visualização do esquema de casualização do experimento, a seguir pode ser observado o *croquis* de um experimento em esquema de fatorial duplo com um tratamento adicional, conduzido em DIC:

$(\alpha_1\beta_b)_J$	Ad₁			$(\alpha_1\beta_1)_J$
		$(\alpha_a\beta_b)_J$		
$(\alpha_1\beta_1)_1$				$(\alpha_a\beta_1)_1$
			$(\alpha_a\beta_b)_1$	
$(\alpha_a\beta_1)_J$		$(\alpha_1\beta_b)_1$		Ad_J

Figura 10: Ilustração de um experimento em esquema de fatorial duplo com um tratamento adicional em DIC, com seus tratamentos obtidos das combinações dos níveis do fator α com os níveis do fator β e os tratamentos adicionais Ad_1, \dots, Ad_J .

A análise de fatoriais duplos com um tratamento adicional no software R, exige pelo menos duas análises e cada uma delas requer diversas linhas de comando.

Para a análise de fatoriais duplos com um tratamento adicional em DIC, normalmente, são necessárias duas análises:

1. Análise de variância do fatorial duplo com desdobramento da interação (caso seja significativa); e
2. Análise de variância de um DIC simples incluindo todos os tratamentos juntamente com o adicional.

A primeira análise é representada pela tabela da ANAVA do fatorial duplo já descrito anteriormente - Tabela (4), e na tabela a seguir, tem-se a análise de variância do DIC simples, onde a fonte de variação $Trat$ corresponde aos tratamentos vindos de um fatorial duplo.

Tabela 11: Tabela da ANAVA para um experimento em DIC simples incluindo todos os tratamentos juntamente com o adicional.

FV	GL	SQ	QM	F_c
Trat	$ab - 1$	SQ_{Tr}	$\frac{SQ_{Tr}}{gl_{Tr}}$	$\frac{QM_{Tr}}{QM_R}$
Adicional vs demais	1	SQ_{Ad}	$\frac{SQ_{Ad}}{1}$	$\frac{QM_{Ad}}{QM_R}$
Resíduo	$(ab + 1)J - 1 - ab$	SQ_R	$\frac{SQ_R}{gl_R}$	
Total	$(ab + 1)J - 1$	SQ_T	$\frac{SQ_T}{gl_T}$	

A partir destas duas tabelas, a tabela de análise de variância do experimento em questão - fatorial duplo com um tratamento adicional em DIC - pode ser observada abaixo:

Tabela 12: Tabela da ANAVA para um experimento em fatorial duplo com um tratamento adicional, em DIC.

FV	GL	SQ	QM	F_c
α	$a - 1$	SQ_α	$\frac{SQ_\alpha}{gl_\alpha}$	$\frac{QM_\alpha}{QM_R}$
β	$b - 1$	SQ_β	$\frac{SQ_\beta}{gl_\beta}$	$\frac{QM_\beta}{QM_R}$
$\alpha * \beta$	$(a - 1)(b - 1)$	$SQ_{\alpha\beta}$	$\frac{SQ_{\alpha\beta}}{gl_{\alpha\beta}}$	$\frac{QM_{\alpha\beta}}{QM_R}$
Adicional vs demais	1	SQ_{Ad}	$\frac{SQ_{Ad}}{1}$	$\frac{QM_{Ad}}{QM_R}$
Resíduo	$(ab + 1)J - 1 - ab$	SQ_R	$\frac{SQ_R}{gl_R}$	
Total	$(ab + 1)J - 1$	SQ_T	$\frac{SQ_T}{gl_T}$	

A soma de quadrados do contraste do tratamento adicional com o fatorial (SQ_{Ad}) pode ser calculada por diferença entre a soma de quadrados dos tratamentos (SQ_{Tr}) da Tabela (11) e as somas de quadrados dos fatores α e β e sua interação (SQ_α , SQ_β e $SQ_{\alpha\beta}$) da Tabela (4) (HEALY, 1956), ou seja:

$$SQ_{Ad} = SQ_{Tr} - (SQ_\alpha + SQ_\beta + SQ_{\alpha\beta}).$$

O resíduo utilizado foi o encontrado na Tabela (11) e, desta forma, os quantis da distribuição F (F_c) foram recalculados.

O teste F para esta situação é importante para o contraste entre o tratamento adicional e os demais tratamentos (*Adicional vs demais*), em que o F_t desta fonte de variação é função da significância estabelecida (α), dos graus de liberdade do contraste (ν_1) e dos graus de liberdade do resíduo (ν_2).

Considerando um fatorial duplo com um tratamento adicional em DBC, o modelo estatístico se torna:

$$Y = \begin{cases} \mu + \lambda_k + \alpha_i + \beta_j + (\alpha\beta)_{ij} + e_{ijk}, & \text{se } Y = Y_{ijkl} \in \text{fatorial} \\ \mu + \lambda_k + \tau + e_k, & \text{se } Y = Y_k \notin \text{fatorial} \end{cases}$$

em que todos os efeitos já foram explicados anteriormente.

Para melhor visualização do esquema de casualização do experimento, a seguir pode ser observado o *croquis* de um experimento em esquema de fatorial duplo com um tratamento adicional, conduzido em DBC:

λ_1	$\alpha_a\beta_b$	Ad_1	$\alpha_1\beta_1$	
λ_2	Ad_2	$\alpha_1\beta_1$		$\alpha_a\beta_b$
\vdots				
λ_J	$\alpha_1\beta_1$	$\alpha_a\beta_b$		Ad_J

Figura 11: Ilustração de um experimento em esquema de fatorial duplo com um tratamento adicional em DBC, com seus tratamentos obtidos das combinações dos níveis do fator α com os níveis do fator β , mais os tratamentos adicionais Ad_1, Ad_2, \dots, Ad_J , nos blocos $\lambda_1, \lambda_2, \dots, \lambda_J$.

Para a análise de fatoriais duplos com um tratamento adicional em DBC, normalmente, são necessárias duas análises:

1. Análise de variância do fatorial duplo com desdobramento da interação (caso seja significativa); e
2. Análise de variância de um DBC simples incluindo todos os tratamentos juntamente com o adicional.

A primeira análise é representada pela tabela da ANAVA do fatorial duplo já descrito anteriormente - Tabela (4), e na tabela a seguir, tem-se a análise de variância do DBC simples, onde a fonte de variação *Trat* corresponde aos tratamentos vindos de um fatorial duplo.

Tabela 13: Tabela da ANAVA para um experimento em DBC simples incluindo todos os tratamentos juntamente com o adicional.

FV	GL	SQ	QM	F_c
Bloco	$J - 1$	SQ_B	$\frac{SQ_B}{gl_B}$	$\frac{QM_B}{QM_R}$
Trat	$ab - 1$	SQ_{Tr}	$\frac{SQ_{Tr}}{gl_{Tr}}$	$\frac{QM_{Tr}}{QM_R}$
Adicional vs demais	1	SQ_{Ad}	$\frac{SQ_{Ad}}{1}$	$\frac{QM_{Ad}}{QM_R}$
Resíduo	$ab(J - 1)$	SQ_R	$\frac{SQ_R}{gl_R}$	
Total	$(ab + 1)J - 1$	SQ_T	$\frac{SQ_T}{gl_T}$	

A partir destas duas tabelas, a tabela de análise de variância do experimento em questão - fatorial duplo com um tratamento adicional em DBC - pode ser observada abaixo:

Tabela 14: Tabela da ANAVA para um experimento em fatorial duplo com um tratamento adicional, em DBC.

FV	GL	SQ	QM	F_c
<i>Bloco</i>	$J - 1$	SQ_B	$\frac{SQ_B}{gl_B}$	$\frac{QM_B}{QM_R}$
α	$a - 1$	SQ_α	$\frac{SQ_\alpha}{gl_\alpha}$	$\frac{QM_\alpha}{QM_R}$
β	$b - 1$	SQ_β	$\frac{SQ_\beta}{gl_\beta}$	$\frac{QM_\beta}{QM_R}$
$\alpha * \beta$	$(a - 1)(b - 1)$	$SQ_{\alpha\beta}$	$\frac{SQ_{\alpha\beta}}{gl_{\alpha\beta}}$	$\frac{QM_{\alpha\beta}}{QM_R}$
Adicional vs Fatorial	1	SQ_{Ad}	$\frac{SQ_{Ad}}{1}$	$\frac{QM_{Ad}}{QM_R}$
Resíduo	$ab(J - 1)$	SQ_R	$\frac{SQ_R}{gl_R}$	
Total	$(ab + 1)J - 1$	SQ_T	$\frac{SQ_T}{gl_T}$	

A soma de quadrados do contraste do tratamento adicional com o fatorial (SQ_{Ad}) pode ser calculada por diferença entre a soma de quadrados dos tratamentos (SQ_{Tr}) da Tabela (13) e as somas de quadrados do bloco, dos fatores α e β e sua interação (SQ_B , SQ_α , SQ_β e $SQ_{\alpha\beta}$) da Tabela (4) (HEALY, 1956), ou seja:

$$SQ_{Ad} = SQ_{Tr} - (SQ_B + SQ_\alpha + SQ_\beta + SQ_{\alpha\beta}).$$

O resíduo utilizado foi o encontrado na Tabela (13) e, desta forma, os quantis da distribuição F (F_c) foram recalculados.

Considerando agora um experimento em fatorial triplo com um tratamento adicional conduzido em DIC, o modelo estatístico é o seguinte:

$$Y = \begin{cases} \mu + \alpha_i + \beta_j + \gamma_k + (\alpha\beta)_{ij} + (\alpha\gamma)_{ik} + (\beta\gamma)_{jk} + (\alpha\beta\gamma)_{ijk} + e_{ijkl}, & \text{se } Y = Y_{ijkl} \in \text{fatorial} \\ \mu + \tau + e_l, & \text{se } Y = Y_l \notin \text{fatorial} \end{cases}$$

em que, além dos efeitos já explicados na seção (4.4), τ é o contraste entre o fatorial triplo e o tratamento adicional.

Para melhor visualização do esquema de casualização do experimento, a seguir pode ser observado o *croquis* de um experimento em esquema de fatorial triplo com um tratamento adicional, conduzido em DIC:

Ad_j				$(\alpha_1\beta_1\gamma_1)_J$
		$(\alpha_2\beta_b\gamma_c)_J$		
$(\alpha_1\beta_1\gamma_1)_1$		Ad_1		
			$(\alpha_2\beta_b\gamma_c)_1$	

Figura 12: Ilustração de um experimento em esquema de fatorial triplo com um tratamento adicional em DIC, com seus tratamentos obtidos das combinações dos níveis do fator α com os níveis do fator β e os níveis do fator γ , mais os tratamentos adicionais Ad_1, \dots, Ad_J .

Para a análise de fatoriais triplos com um tratamento adicional em DIC também são necessárias, normalmente, duas análises:

1. Análise de variância do fatorial triplo com desdobramento da interação (caso seja significativa); e
2. Análise de variância de um DIC simples incluindo todos os tratamentos juntamente com o adicional.

A primeira análise também já está representada pela tabela da ANAVA do fatorial triplo descrito anteriormente - Tabela (6), e na tabela a seguir, tem-se a análise de variância do DIC simples, onde a fonte de variação *Trat* corresponde aos tratamentos vindos de um fatorial triplo.

Tabela 15: Tabela da ANAVA para um experimento em DIC simples incluindo todos os tratamentos juntamente com o adicional.

FV	GL	SQ	QM	F_c
Trat	$abc - 1$	SQ_{Tr}	$\frac{SQ_{Tr}}{gl_{Tr}}$	$\frac{QM_{Tr}}{QM_R}$
Adicional vs demais	1	SQ_{Ad}	$\frac{SQ_{Ad}}{1}$	$\frac{QM_{Ad}}{QM_R}$
Resíduo	$(abc + 1)J - 1 - abc$	SQ_R	$\frac{SQ_R}{gl_R}$	
Total	$(abc + 1)J - 1$	SQ_T	$\frac{SQ_T}{gl_T}$	

A partir destas duas tabelas, a tabela de análise de variância do experimento em questão - fatorial triplo com um tratamento adicional em DIC - pode ser observada abaixo:

Tabela 16: Tabela da ANAVA para um experimento em fatorial triplo com um tratamento adicional, em DIC.

FV	GL	SQ	QM	F_c
α	$a - 1$	SQ_α	$\frac{SQ_\alpha}{gl_\alpha}$	$\frac{QM_\alpha}{QM_R}$
β	$b - 1$	SQ_β	$\frac{SQ_\beta}{gl_\beta}$	$\frac{QM_\beta}{QM_R}$
γ	$c - 1$	SQ_γ	$\frac{SQ_\gamma}{gl_\gamma}$	$\frac{QM_\gamma}{QM_R}$
$\alpha * \beta$	$(a - 1)(b - 1)$	$SQ_{\alpha\beta}$	$\frac{SQ_{\alpha\beta}}{gl_{\alpha\beta}}$	$\frac{QM_{\alpha\beta}}{QM_R}$
$\alpha * \gamma$	$(a - 1)(c - 1)$	$SQ_{\alpha\gamma}$	$\frac{SQ_{\alpha\gamma}}{gl_{\alpha\gamma}}$	$\frac{QM_{\alpha\gamma}}{QM_R}$
$\beta * \gamma$	$(b - 1)(c - 1)$	$SQ_{\beta\gamma}$	$\frac{SQ_{\beta\gamma}}{gl_{\beta\gamma}}$	$\frac{QM_{\beta\gamma}}{QM_R}$
$\alpha * \beta * \gamma$	$(a - 1)(b - 1)(c - 1)$	$SQ_{\alpha\beta\gamma}$	$\frac{SQ_{\alpha\beta\gamma}}{gl_{\alpha\beta\gamma}}$	$\frac{QM_{\alpha\beta\gamma}}{QM_R}$
Adicional vs Fatorial	1	SQ_{Ad}	$\frac{SQ_{Ad}}{1}$	$\frac{QM_{Ad}}{QM_R}$
Resíduo	$(abc + 1)J - 1 - abc$	SQ_R	$\frac{SQ_R}{gl_R}$	
Total	$(abc + 1)J - 1$	SQ_T	$\frac{SQ_T}{gl_T}$	

A soma de quadrados do contraste do tratamento adicional com o fatorial (SQ_{Ad}) pode ser calculada por diferença entre a soma de quadrados dos tratamentos (SQ_{Tr}) da Tabela (15) e as somas de quadrados dos fatores α , β e γ e suas interações (SQ_α , SQ_β , SQ_γ , $SQ_{\alpha\beta}$, $SQ_{\alpha\gamma}$, $SQ_{\beta\gamma}$ e $SQ_{\alpha\beta\gamma}$) da Tabela (6) (HEALY, 1956), ou seja:

$$SQ_{Ad} = SQ_{Tr} - (SQ_\alpha + SQ_\beta + SQ_\gamma + SQ_{\alpha\beta} + SQ_{\alpha\gamma} + SQ_{\beta\gamma} + SQ_{\alpha\beta\gamma}).$$

O resíduo utilizado foi o encontrado na Tabela (15) e, desta forma, os quantis da distribuição F (F_c) foram recalculados.

Considerando agora um experimento em fatorial triplo com um tratamento adicional

conduzido em DBC, o modelo estatístico se torna:

$$Y = \begin{cases} \mu + \lambda_l + \alpha_i + \beta_j + \gamma_k + (\alpha\beta)_{ij} + (\alpha\gamma)_{ik} + (\beta\gamma)_{jk} + (\alpha\beta\gamma)_{ijk} + e_{ijkl}, & \text{se } Y = Y_{ijkl} \in \text{fatorial} \\ \mu + \lambda_l + \tau + e_l, & \text{se } Y = Y_l \notin \text{fatorial} \end{cases}$$

em que todos os efeitos já foram explicados anteriormente.

Para melhor visualização do esquema de casualização do experimento, a seguir pode ser observado o *croquis* de um experimento em esquema de fatorial triplo com um tratamento adicional, conduzido em DBC:

λ_1	Ad₁	$\alpha_a\beta_b\gamma_c$		$\alpha_1\beta_1\gamma_1$
λ_2	$\alpha_1\beta_1\gamma_1$		Ad₂	$\alpha_a\beta_b\gamma_c$
\vdots				
λ_J		$\alpha_1\beta_1\gamma_1$	$\alpha_a\beta_b\gamma_c$	Ad_J

Figura 13: Ilustração de um experimento em esquema de fatorial triplo com um tratamento adicional em DBC, com seus tratamentos obtidos das combinações dos níveis do fator α com os níveis do fator β e os níveis do fator γ , e mais os tratamentos adicionais Ad_1, \dots, Ad_J , nos blocos $\lambda_1, \lambda_2, \dots, \lambda_J$.

Para a análise de fatoriais triplos com um tratamento adicional em DBC também são necessárias, normalmente, duas análises:

1. Análise de variância do fatorial triplo com desdobramento da interação (caso seja significativa); e
2. Análise de variância de um DBC simples incluindo todos os tratamentos juntamente com o adicional.

A primeira análise também já está representada pela tabela da ANAVA do fatorial triplo descrito anteriormente - Tabela (6), e na tabela a seguir, tem-se a análise de variância do DBC simples, onde a fonte de variação *Trat* corresponde aos tratamentos vindos de um fatorial triplo.

Tabela 17: Tabela da ANAVA para um experimento em DBC simples incluindo todos os tratamentos juntamente com o adicional.

FV	GL	SQ	QM	F_c
Bloco	$J - 1$	SQ_B	$\frac{SQ_B}{gl_B}$	$\frac{QM_B}{QM_R}$
Trat	$abc - 1$	SQ_{Tr}	$\frac{SQ_{Tr}}{gl_{Tr}}$	$\frac{QM_{Tr}}{QM_R}$
Adicional vs demais	1	SQ_{Ad}	$\frac{SQ_{Ad}}{1}$	$\frac{QM_{Ad}}{QM_R}$
Resíduo	$abc(J - 1)$	SQ_R	$\frac{SQ_R}{gl_R}$	
Total	$(abc + 1)J - 1$	SQ_T	$\frac{SQ_T}{gl_T}$	

A partir destas duas tabelas, a tabela de análise de variância do experimento em questão - fatorial triplo com um tratamento adicional em DBC - pode ser observada abaixo:

Tabela 18: Tabela da ANAVA para um experimento em fatorial triplo com um tratamento adicional, em DBC.

FV	GL	SQ	QM	F_c
Bloco	$J - 1$	SQ_B	$\frac{SQ_B}{gl_B}$	$\frac{QM_B}{QM_R}$
α	$a - 1$	SQ_α	$\frac{SQ_\alpha}{gl_\alpha}$	$\frac{QM_\alpha}{QM_R}$
β	$b - 1$	SQ_β	$\frac{SQ_\beta}{gl_\beta}$	$\frac{QM_\beta}{QM_R}$
γ	$c - 1$	SQ_γ	$\frac{SQ_\gamma}{gl_\gamma}$	$\frac{QM_\gamma}{QM_R}$
$\alpha * \beta$	$(a - 1)(b - 1)$	$SQ_{\alpha\beta}$	$\frac{SQ_{\alpha\beta}}{gl_{\alpha\beta}}$	$\frac{QM_{\alpha\beta}}{QM_R}$
$\alpha * \gamma$	$(a - 1)(c - 1)$	$SQ_{\alpha\gamma}$	$\frac{SQ_{\alpha\gamma}}{gl_{\alpha\gamma}}$	$\frac{QM_{\alpha\gamma}}{QM_R}$
$\beta * \gamma$	$(b - 1)(c - 1)$	$SQ_{\beta\gamma}$	$\frac{SQ_{\beta\gamma}}{gl_{\beta\gamma}}$	$\frac{QM_{\beta\gamma}}{QM_R}$
$\alpha * \beta * \gamma$	$(a - 1)(b - 1)(c - 1)$	$SQ_{\alpha\beta\gamma}$	$\frac{SQ_{\alpha\beta\gamma}}{gl_{\alpha\beta\gamma}}$	$\frac{QM_{\alpha\beta\gamma}}{QM_R}$
Adicional vs Fatorial	1	SQ_{Ad}	$\frac{SQ_{Ad}}{1}$	$\frac{QM_{Ad}}{QM_R}$
Resíduo	$abc(J - 1)$	SQ_R	$\frac{SQ_R}{gl_R}$	
Total	$(abc + 1)J - 1$	SQ_T	$\frac{SQ_T}{gl_T}$	

A soma de quadrados do contraste do tratamento adicional com o fatorial (SQ_{Ad}) pode ser calculada por diferença entre a soma de quadrados dos tratamentos (SQ_{Tr}) da Tabela (17) e as somas de quadrados do bloco, dos fatores α , β e γ e suas interações (SQ_B , SQ_α , SQ_β , SQ_γ , $SQ_{\alpha\beta}$, $SQ_{\alpha\gamma}$, $SQ_{\beta\gamma}$ e $SQ_{\alpha\beta\gamma}$) da Tabela (6) (HEALY, 1956), ou seja:

$$SQ_{Ad} = SQ_{Tr} - (SQ_B + SQ_\alpha + SQ_\beta + SQ_\gamma + SQ_{\alpha\beta} + SQ_{\alpha\gamma} + SQ_{\beta\gamma} + SQ_{\alpha\beta\gamma}).$$

O resíduo utilizado foi o encontrado na Tabela (17) e, desta forma, os quantis da distribuição F (F_c) foram recalculados.

4.7 Teste de Normalidade de Shapiro-Wilk

O teste de Shapiro-Wilk é baseado em estatísticas de ordem da distribuição normal e de seus respectivos valores esperados ou médios. Para esclarecer melhor os conceitos dessas estatísticas, suponha que de uma população normal sejam repetidamente retiradas amostras aleatórias de tamanho n , ou seja, X_1, X_2, \dots, X_n . Os n valores são ordenados de forma crescente $X_{(1)}, X_{(2)}, \dots, X_{(n)}$ em cada amostra retirada. Cada número individualmente é denominado de estatística de ordem. O valor esperado da i -ésima estatística de ordem é a média do valor $X_{(i)}$ em repetidas amostras aleatórias de tamanho n retiradas da população. Seja m_i a medida dessa estatística de ordem para uma população normal padrão, ou seja, de uma normal com média $\mu = 0$ e variância $\sigma^2 = 1$ e seja $Z_{(1)}, Z_{(2)}, \dots, Z_{(n)}$ uma amostra aleatória da distribuição normal, então

$$E(Z_{(i)}) = m_i$$

é denominado de valor esperado da i -ésima estatística de ordem da distribuição normal padrão.

Valores exatos de m_i podem ser calculados, embora envolvam integrais laboriosas. Aproximações para esse valor médio podem ser obtidas com base no cálculo de quantis da distribuição normal padrão.

A estatística (W) do teste de Shapiro-Wilk (1965) é apresentada a seguir:

$$W = \frac{\left[\sum_{i=1}^n a_i X_{(i)} \right]^2}{(n-1)S^2} = \frac{\left[\sum_{i=1}^n a_i X_{(i)} \right]^2}{\sum_{i=1}^n X_i^2 - \frac{\left(\sum_{i=1}^n X_i \right)^2}{n}}$$

Essa expressão é dependente da variância amostral S^2 e do coeficiente a_i , que é denominado por melhor estimador linear não-viesado normalizado do valor esperado das estatísticas de ordem da distribuição normal padrão (FERREIRA, 2005). A determinação exata desses coeficientes é dependente da determinação exata dos valores esperados e da matriz de variâncias e covariâncias das estatísticas de ordem da distribuição normal padrão.

Esta estatística W foi desenvolvida para o teste da hipótese de normalidade da população amostrada, em que:

H_0 : os dados amostrais são provenientes de uma população normal

vs

H_1 : os dados amostrais não são provenientes de uma população normal

Na sequencia, deve-se determinar a distribuição nula de W ou os valores críticos para

valores nominais específicos da significância para se realizar o teste da hipótese nula de normalidade dos dados.

Com o p-valor computado, a decisão de rejeição ou não de H_0 pode ser tomada, comparando-se o valor obtido com o valor nominal da significância α adotado. O teste de Shapiro-Wilk é considerado um excelente teste, com poder superior ao de seus concorrentes na maioria das situações e com taxas de erro tipo I sempre em consonância com o valor nominal adotado de significância (α), mesmo para pequenos valores de n , ou seja, pode-se afirmar que é um teste cujo tamaho é α .

4.8 Regressão Linear na Análise de Variância

A regressão é uma técnica de análise que utiliza a relação entre duas ou mais variáveis quantitativas para determinar um modelo matemático de forma que o efeito de uma possa ser previsto por meio da outra variável (ou outras variáveis). Na análise de experimentos, o modelo matemático mais empregado para tentar explicar o efeito dos tratamentos na variável resposta é o modelo polinomial. Os polinômios são da forma:

$$Y = \beta_0 + \beta_1 X + \dots + \beta_p X^p$$

Os mais utilizados são:

- Polinômio do 1º grau ou Regressão Linear: $Y = \beta_0 + \beta_1 X$
- Polinômio do 2º grau ou Regressão Quadrática: $Y = \beta_0 + \beta_1 X + \beta_2 X^2$
- Polinômio do 3º grau ou Regressão Cúbica: $Y = \beta_0 + \beta_1 X + \beta_2 X^2 + \beta_3 X^3$

Em todos os modelos estão envolvidas apenas duas variáveis: X e Y (DRAPER & SMITH, 1998). No caso dos experimentos, a variável X, ou variável independente, é uma variável não aleatória corresponde aos tratamentos e a variável Y, ou variável dependente, que é a variável resposta (variável aleatória). Por exemplo, em um DIC simples, $X = \alpha_i$ e $Y = Y_{ij}$, em que $i = 1, 2, \dots, I$ e $j = 1, 2, \dots, J$.

O método de regressão na análise de variância consiste em determinar se um desses polinômios explica satisfatoriamente a relação entre os tratamentos utilizados e as observações. Para tanto, será empregado o teste F para determinar quais são os modelos possíveis e o coeficiente de determinação (R^2) para mostrar o grau de explicação de cada modelo.

O teste F na análise de variância permite testar apenas o coeficiente associado à variável X no seu maior expoente, testando-se assim o efeito de grau p . Para cada polinômio, as hipóteses do teste F serão:

$$Y = \beta_0 + \beta_1 X + \beta_2 X^2 + \beta_3 X^3 + \dots + \beta_p X^p$$

$$H_0 : \beta_p = 0$$

$$H_1 : \beta_p \neq 0$$

(Efeito do grau p)

Os passos para a análise de regressão são:

1. Definir os efeitos de regressão a serem testados. A cada efeito de regressão corresponde 1 grau de liberdade. Assim, é possível testar tantos efeitos de regressão quantos são os graus de liberdade para tratamentos;

2. Determinar as Somas de Quadrados para cada um destes efeitos de regressão; a Soma de Quadrados do Efeito Linear (SQ_{EL}), por exemplo, pode ser calculada pela fórmula:

$$SQ_{EL} = \frac{\left[\sum XY - \frac{(\sum X)(\sum Y)}{I} \right]^2}{\sum X^2 - \frac{(\sum X)^2}{I}} \cdot J$$

em que I é o número de médias e J o número de repetições;

3. No quadro da Análise de Variância, testar os efeitos de regressão utilizando o Quadrado Médio do Resíduo;
4. Através do teste F, definir o grau do polinômio que melhor se ajusta às médias de características observadas;
5. Determinar o grau de ajuste, através do Coeficiente de Determinação:

$$R^2 = \frac{SQR}{SQTr} \cdot 100$$

em que $SQR = \sum$ (Somas de Quadrados dos Efeitos de Regressão);

6. Obter as estimativas dos parâmetros do modelo de Regressão escolhido e apresentar os resultados em um gráfico. Por exemplo, para um Modelo de Regressão Linear, tem-se as estimativas de β_0 e β_1 :

$$\hat{\beta}_1 = \frac{\sum XY - \frac{(\sum X)(\sum Y)}{I}}{\sum X^2 - \frac{(\sum X)^2}{I}}$$

$$\hat{\beta}_0 = \frac{\sum Y}{I} - \hat{\beta}_1 \frac{\sum X}{I}$$

Na análise de variância da regressão, tomando um experimento em DIC ajustado até o modelo parábola, observa-se que a fonte de variação tratamento é desdobrada em efeitos de regressão e desvios de regressão. Os efeitos de uma regressão quadrática são: efeito linear (β_1) e efeito quadrático (β_2) e recebem um grau de liberdade cada. Desta forma o grau de liberdade dos desvios é obtido pela diferença entre o grau de liberdade dos tratamentos e os graus de liberdade dos efeitos (LIMA & ABREU, 2000).

Tabela 19: Regressão linear na ANAVA até o modelo quadrático.

FV	GL	SQ	QM	F_c
β_1	1	SQ_{EL}	$\frac{SQ_{EL}}{gl_{EL}}$	$\frac{QM_{EL}}{QM_R}$
β_2	1	SQ_{EQ}	$\frac{SQ_{EQ}}{gl_{EQ}}$	$\frac{QM_{EQ}}{QM_R}$
Desvios	$(I - 1) - 2$	SQ_D	$\frac{SQ_D}{gl_D}$	$\frac{QM_D}{QM_R}$
Resíduo	$J(I - 1)$	SQ_R	$\frac{SQ_R}{gl_R}$	
Total	$IJ - 1$	SQ_T	$\frac{SQ_T}{gl_T}$	

O teste F na regressão é realizado para os efeitos de regressão e desvios de regressão, em que o F_t é função da significância estabelecida (α), dos graus de liberdade dos efeitos ou dos desvios (ν_1), respectivamente, e dos graus de liberdade do resíduo (ν_2).

Em um modelo bem ajustado espera-se que a fonte de variação *Desvios* seja não significativa.

4.9 Testes de comparação múltipla de médias

4.9.1 Teste t de Student (LSD)

O teste t de Student (*Least Significant Difference* - LSD) serve para testar médias de dois tratamentos ou médias de dois grupos de tratamentos (caso em que o contraste tem mais de duas médias envolvidas).

Para sua aplicação correta, deve-se considerar os seguintes requisitos básicos:

- a) Os contrastes a serem testados devem ser estabelecidos antes de obtidos os dados experimentais;
- b) Os contrastes a serem testados devem ser ortogonais entre si.

Quando o teste t é aplicado a um contraste qualquer, tem-se o interesse em verificar se a estimativa do contraste (\hat{Y}) difere ou não de zero (valor que o contraste deveria assumir se a hipótese da nulidade fosse verdadeira).

Então são testadas: $H_0 : Y = 0$ vs $H_1 : Y \neq 0$.

Aplicação do teste t:

Num experimento com I tratamentos e J repetições, considerando o seguinte contraste:

$$Y = c_1 m_1 + c_2 m_2 + \dots + c_I m_I$$

- a) Calcular a estimativa do contraste - \hat{Y}

$$\hat{Y} = c_1 \hat{m}_1 + c_2 \hat{m}_2 + \dots + c_I \hat{m}_I$$

- b) Calcular a estimativa de variância da estimativa do contraste - $\hat{V}(\hat{Y})$

$$\hat{V}(\hat{Y}) = (c_1^2 + c_2^2 + \dots + c_I^2) \frac{s^2}{J}$$

- c) Calcular o erro padrão do contraste - $s(\hat{Y})$

$$s(\hat{Y}) = \sqrt{\hat{V}(\hat{Y})}$$

- d) Calcular o valor da estatística do teste, t , por:

$$t = \frac{\hat{Y}}{s(\hat{Y})}$$

- e) Procurar numa tabela da distribuição de t (dos níveis de 5% e 1%), os valores tabelados, em função do número de graus de liberdade do resíduo.

- f) Comparar o valor de t calculado (em valor absoluto) com o valor de t da tabela:

- Se $|t| > t_{tab}$, o teste é significativo, rejeita-se H_0 para Y e conclui-se que as médias

dos tratamentos (ou grupos) testados no contraste diferem.

- Se $|t| < t_{tab}$, o teste não é significativo, aceita-se H_0 para Y e conclui-se que as médias dos tratamentos (ou grupos) testados no contraste não diferem.

g) Indicar a significância do teste, no valor do t calculado:

NS - teste não significativo no nível de 5% de probabilidade.

* - teste significativo no nível de 5% de probabilidade.

** - teste significativo no nível de 1% de probabilidade (BANZATTO & KRONKA, 2006).

4.9.2 Teste t de Student com proteção de Bonferroni

Para o emprego do teste t (LSD), há algumas restrições; contudo, alguns pesquisadores optam por utilizar esse teste também para qualquer tipo de comparações múltiplas. No entanto, esse teste possui o inconveniente de ter a maior taxa de erro por experimento em relação a todos os outros que serão abordados neste trabalho. Neste teste a DMS (LSD) é dada por:

$$LSD = t_{\nu, \alpha/2} \sqrt{\hat{V}D} = t_{\nu, \alpha/2} \sqrt{s} \sqrt{\frac{QMR}{J}}$$

em que o valor $t_{\nu, \alpha/2}$ representa o quantil da distribuição de t de student com ν graus de liberdade, que deixa uma área (probabilidade) acima do mesmo de $\alpha/2$.

Muitos estatísticos recomendam o LSD somente para realizar comparações planejadas inicialmente e jamais para as inferências sugeridas pelos dados. O fato de se utilizar neste procedimento a mesma estimativa da DMS, a qual utiliza uma única estimativa do quadrado médio residual, torna os testes (inferências) sobre um mesmo fator (tratamento) não independente e, portanto, o nível global de significância não é mantido ou preservado.

Uma alternativa para se preservar a taxa de erro po experimento baseia-se na desigualdade de Bonferroni para um evento probabilístico. O resultado efetivo desse procedimento é a alteração do nível de significância para a determinação do valor tabelado de t, dividindo-se o nível nominal pelo número de inferências que serão realizadas. No caso de se realizarem todas as comparações múltiplas 2 a 2, o nível de significância será:

$$\alpha_p = \frac{2\alpha}{n(n-1)}$$

Assim, a DMS (LSDB) do teste t de Bonferroni é:

$$LSDB = t_{\nu, \alpha_p/2} \sqrt{\hat{V}D} = t_{\nu, \alpha_p/2} \sqrt{s} \sqrt{\frac{QMR}{J}}$$

(RAMALHO; FERREIRA; OLIVEIRA, 2005).

4.9.3 Teste de Tukey

O Teste de Tukey serve para testar qualquer contraste entre duas médias de tratamento. O número de contrastes que podem ser testados consiste no número de combinações das médias, duas a duas (ZIMMERMANN, 2004). Assim, num experimento com 5 tratamentos, por exemplo, podem-se testar até 10 contrastes de duas médias de tratamentos.

Este teste é baseado na amplitude estudentizada, que é função do número de tratamentos, do número de graus de liberdade do resíduo e da significância do teste (por ser um teste rigoroso, ou seja, por exigir uma grande diferença entre as médias para se concluir que dois tratamentos são diferentes, geralmente, o teste de Tukey é aplicado apenas no nível de 5% de probabilidade). Os contrastes são realizados através da diferença mínima significativa (DMS), a qual depende da amplitude estudentizada, do quadrado médio do resíduo e do número de repetições (GOMES, 2009).

Aplicação do teste de Tukey:

a) Calcular a diferença mínima significativa, representada por Δ , da seguinte forma:

$$\Delta = q \frac{s}{\sqrt{J}}$$

em que q é a amplitude total estudentizada, para uso no teste de Tukey, encontrada em tabelas, em função do número de tratamentos (na horizontal) e do número de graus de liberdade do resíduo (na vertical); $s = \sqrt{QMR}$; J - número de repetições com que foram calculadas as médias.

b) Calcular as estimativas dos contrastes de duas médias - \hat{Y} .

c) Comparar cada estimativa de contraste, em valor absoluto ($|\hat{Y}|$), com a diferença mínima significativa (Δ):

- Se $|\hat{Y}| \geq \Delta$, o teste é significativo, o que indica que as duas médias de Y diferem;
- Se $|\hat{Y}| < \Delta$, o teste não é significativo, o que indica que as duas médias de Y não diferem.

d) Indicar a significância do teste no valor da estimativa do contraste (\hat{Y}) (BANZATTO & KRONKA, 2006).

4.9.4 Teste de Duncan

O teste de Duncan é menos rigoroso que o teste de Tukey, mas é de aplicação mais trabalhosa. O teste exige que as médias sejam colocadas em ordem decrescente de valores e que todas as médias possuam o mesmo número de repetições para ser exato.

Normalmente, o teste é aplicado no nível de 5% de probabilidade, e a significância do teste é representada ligando-se, por uma barra contínua, duas médias que não diferem.

Em cada contraste só podemos comparar duas médias, mas a diferença entre elas pode abranger duas ou mais médias.

Aplicação do teste de Duncan:

Considerando um experimento com I tratamentos, cujas médias foram todas calculadas com r repetições:

- (a) Colocar as I médias dos tratamentos em ordem decrescente.
- (b) Calcular a estimativa do contraste:

$$\hat{Y}_1 = \hat{m}_{\text{maior}} - \hat{m}_{\text{menor}}$$

- (c) Calcular o valor da amplitude total mínima significativa, D_I , dada por:

$$D_I = z_I \frac{s}{\sqrt{J}}$$

em que z_I - é a amplitude total estudentizada, para uso do teste de Duncan, encontrada em tabelas, em função do número de médias abrangidas pelo contraste (na horizontal) e do número de graus de liberdade do resíduo (na vertical); $s = \sqrt{QMR}$; J é o número de repetições com que foram calculadas as médias.

- (d) Comparar \hat{Y}_1 com D_I :

- Se $\hat{Y}_1 < D_I$, o teste não é significativo, indicando que as duas médias que entraram no contraste \hat{Y}_1 não diferem. Então, as médias abrangidas pelo contraste são ligadas por uma barra contínua e não se pode mais comparar médias dentro da barra.
- Se $\hat{Y}_1 \geq D_I$, o teste é significativo, indicando que as duas médias que entraram no contraste \hat{Y}_1 diferem. Então, passam-se a ser testados os contrastes que abrangem um número imediatamente inferior de médias ($I - 1$).

- (e) Calcular as estimativas dos contrastes:

$$\hat{Y}_2 = \hat{m}_{\text{maior}} - \hat{m}_{\text{penúltima}}$$

$$\hat{Y}_3 = \hat{m}_{\text{segunda}} - \hat{m}_{\text{menor}}$$

- (f) Calcular o novo valor de $D \Rightarrow D_{(I-1)}$ (muda o valor de z)

$$D_{(I-1)} = z_{I-1} \frac{s}{\sqrt{J}}$$

(g) Comparar: \hat{Y}_2 com $D_{(I-1)}$ e \hat{Y}_3 com $D_{(I-1)}$.

O processo deve continuar, até que todas as médias abrangidas estejam unidas por barras, ou que tenham sido testados os contrastes que abrangem duas médias (BANZATTO & KRONKA, 2006).

4.9.5 Teste de Student-Newman-Keuls (SNK)

É um teste aplicado da mesma forma que o teste de Duncan, com a diferença que, ao calcularmos a amplitude total mínima significativa do teste, W_I , utilizamos os valores da tabela de Tukey, em vez de utilizarmos os valores da tabela de Duncan.

Então, o teste de Student-Newman-Keuls é um teste intermediário entre o teste de Tukey (mais rigoroso) e o teste de Duncan (menos rigoroso).

Na aplicação do teste, o valor da amplitude total mínima significativa (W_I), para um contraste que abrange I médias, é calculado por:

$$W_I = q \frac{s}{\sqrt{J}}$$

em que q é o valor obtido na tabela do teste de Tukey, em função do número de médias abrangidas pelo contraste (na horizontal) e do número de graus de liberdade do resíduo (na vertical); $s = \sqrt{QMR}$; J é número de repetições com que foram calculadas as médias (BANZATTO & KRONKA, 2006).

4.9.6 Teste de Scott-Knott

O procedimento de Scott e Knott utiliza a razão de verossimilhança para testar a significância de que os I tratamentos podem ser divididos em dois grupos que maximizem a soma de quadrados entre grupos.

Seja, por exemplo, 3 tratamentos A, B e C. O processo consiste em determinar uma partição, em dois grupos, que maximize a soma de quadrados. Veja que neste caso são possíveis $2^{I-1} - 1$ grupos, isto é, A vs B e C, B vs A e C e C vs A e B. Com um número pequeno de tratamentos como o do exemplo, é fácil obter todos os grupos, contudo, quando o número (I) de tratamentos é grande, o número de grupos cresce exponencialmente, dificultando a aplicação do teste. Para atenuar esse problema, basta ordenar as médias dos tratamentos. Nessa situação, o número de partições possíveis passa a ser obtido por $I - 1$. Uma vez ordenadas as médias, procede-se do seguinte modo, fazendo inicialmente o número de tratamentos $g = I$:

- i. Determinar a partição entre dois grupos que maximize a soma de quadrados entre grupos. Essa soma de quadrados está definida por B_0 , e será estimada da seguinte

forma: sejam T_1 e T_2 os totais dos dois grupos com k_1 e k_2 tratamentos em cada um.

$$B_0 = \frac{T_1^2}{k_1} + \frac{T_2^2}{k_2} - \frac{(T_1 + T_2)^2}{k_1 + k_2}$$

$$T_1 = \sum_{i=1}^{k_1} \bar{Y}_{(1)}$$

$$T_2 = \sum_{i=k_1+1}^g \bar{Y}_{(1)}$$

em que $\bar{Y}_{(1)}$ é a medida do tratamento da posição ordenada i .

Os dois grupos deverão ser identificados por meio da inspeção das somas de quadrados das $g - 1$ partições possíveis, sendo g o número de tratamentos envolvidos no grupo de médias considerado.

ii. Determinar o valor da estatística λ da seguinte forma:

$$\lambda = \frac{\pi}{2(\pi - 2)} \times \frac{B_0}{\hat{\sigma}^2}$$

em que $\hat{\sigma}^2$ é o estimador de máxima verossimilhança de σ_Y^2 . Seja

$$s_Y^2 = \frac{QMR}{J}$$

o estimador não viesado de σ_Y^2 e ν os graus de liberdade associados a este estimador.

$$\hat{\sigma}_0^2 = \frac{1}{g + \nu} \left[\sum_{i=1}^g (\bar{Y}_i - \bar{Y})^2 + \nu s_Y^2 \right]$$

- iii. Se $\lambda \geq \chi_{(\alpha; g/(\pi-2))}^2$, rejeita-se a hipótese de que os dois grupos são idênticos em favor da hipótese alternativa de que os dois grupos diferem.
- iv. No caso de rejeitar essa hipótese, os dois subgrupos formados serão independentemente submetidos aos passos (i) a (iii), fazendo respectivamente $g = k_1$ e $g = k_2$. O processo em cada subgrupo se encerra ao aceitar H_0 no passo iii ou se cada subgrupo contiver apenas uma média (RAMALHO; FERREIRA; OLIVEIRA, 2005).

5 Material e Métodos

Para programar as funções foi usada a linguagem R de programação e os softwares R e Tinn-R. Os métodos estatísticos e estimadores utilizados foram os explicados na fundamentação teórica.

Foram utilizadas massas de dados reais e dados simulados para exemplificar as funções programadas:

- O funcionamento da função que analisa experimentos em DICs simples, foi ilustrado com dados de um experimento que teve como objetivo avaliar o consumo da farinha da polpa de yacon sobre o índice glicêmico das dietas experimentais (RIBEIRO, 2008).
- O funcionamento da função que analisa experimentos em DBCs simples, foi ilustrado com dados de uma avaliação sensorial de barras alimentícias, onde provadores (blocos) avaliaram a aparência das barras alimentícias (PAIVA, 2008).
- O funcionamento da função que analisa experimentos em DQLs simples, foi ilustrado com dados adaptados de um experimento que objetivou selecionar forrageiras para minimizar quantitativa e qualitativamente o problema alimentar do rebanho bovino da sub-região dos Paiaguás (COMASTRI FILHO, 1994).
- O funcionamento da função que analisa experimentos em fatorial duplo em DIC, bem como sua saída, foi ilustrado com um subconjunto de dados de um experimento em campo montado para testar a compostagem da casca de café misturada ou não com esterco de bovinos em diferentes intervalos de revolvimento (REZENDE, 2010).
- O funcionamento da função que analisa experimentos em fatorial duplo em DBC, bem como suas saídas, foi ilustrado com dados adaptados de uma análise sensorial, onde provadores de gêneros diferentes avaliaram o sabor de diferentes formulações de barras alimentícias (MOREIRA, 2010).
- O funcionamento da função que analisa experimentos em fatorial duplo com um tratamento adicional, em DIC, bem como sua saída, foi ilustrado com um subconjunto de dados de um experimento sobre compostagem, montado em casas de vegetação, para observar o desempenho da borra resultante da extração do biodiesel, de gorduras e óleos residuários da fritura de alimentos, utilizando-se como fonte de carbono capim napier e como fonte de nitrogênio esterco de bovinos ou torta de mamona, na cultura do sorgo (REZENDE, 2010).
- O funcionamento da função que analisa experimentos em parcelas subdivididas, em DIC, foi ilustrado com um subconjunto de dados de um experimento que estudou

o efeito no pH do solo de coberturas vegetais submetidas a pisoteio predominantemente por animais bovinos, sob sistema de pastoreio contínuo, analisadas em profundidades diferentes (GUERRA, 2010).

- As demais funções, que analisam experimentos: em fatorial duplo com um tratamento adicional em DBC, em fatorial triplo (em DIC e DBC), em fatorial triplo com um tratamento adicional (em DIC e DBC) e em esquema de parcelas subdivididas em DBC, foram ilustradas com dados simulados de uma normal com média $\mu = 0$ e variância $\sigma^2 = 1$; com dois níveis em cada fator e três repetições (ou blocos).

6 Resultados e Discussão

Foram programadas funções em código R para analisar experimentos em delineamentos experimentais simples e em determinados esquemas de análise. Dentre estas funções tem-se: funções principais (rotinas) e funções secundárias ou auxiliares (sub-rotinas), que são utilizadas pelas principais (o usuário não tem acesso direto às sub-rotinas).

6.0.7 Sub-Rotinas

As sub-rotinas programadas permitem o ajuste de modelos sequenciais de regressão e a realização dos testes de comparação múltipla de médias: teste de Tukey, teste de Student-Newman-Keuls, teste de Scott-Knott, teste de Duncan e teste t; nomeadas, respectivamente, `reg.poly`, `HSD.LSD.test`, `HSD.LSDB.test`, `HSD.tukey.test`, `HSD.DUNCAN.test`, `HSD.SNK.test`, `HSD.SCOTTKNOTT.test`.

Regressão Linear na ANAVA

A função `reg.poly` permite o ajuste de modelos sequenciais de regressão linear, dentro do contexto de análise de variância, até o terceiro grau e recebe 6 argumentos, nesta ordem:

```
reg.poly(y, trt, DError, SSError, DFtrt, SStrt)
```

`y`: vetor com a variável-resposta;
`trt`: vetor com os tratamentos;
`DError`: grau de liberdade do resíduo;
`SSError`: soma de quadrados do resíduo;
`DFtrt`: grau de liberdade dos tratamentos; e
`SSstrt`: soma de quadrados dos tratamentos.

Teste t de Student (LSD)

A função `HSD.LSD.test` permite a realização do teste LSD para comparação múltipla de médias e recebe 6 argumentos, nesta ordem:

```
HSD.LSD.test(y, trt, DError, SSError, alpha, group, main)
```

`y`: vetor com a variável-resposta;
`trt`: vetor com os tratamentos;
`DError`: grau de liberdade do resíduo;
`SSError`: soma de quadrados do resíduo;
`alpha=0.05`: significância do teste LSD; o *default* é 0,05;
`group=TRUE`: variável lógica e

main=NULL: título.

Teste t de Student com proteção de Bonferroni (LSDB)

A função `HSD.LSDB.test` permite a realização do teste LSD com proteção de Bonferroni (LSDB) para comparação múltipla de médias e recebe 6 argumentos, nesta ordem:

```
HSD.LSDB.test(y, trt, DError, SSError, alpha, group, main)
```

y: vetor com a variável-resposta;

trt: vetor com os tratamentos;

DError: grau de liberdade do resíduo;

SSError: soma de quadrados do resíduo;

alpha=0.05: significância do teste LSDB; o *default* é 0,05;

group=TRUE: variável lógica e

main=NULL: título.

Teste de Tukey

A função `HSD.tukey.test` permite a realização do teste de Tukey para comparação múltipla de médias e recebe 6 argumentos, nesta ordem:

```
HSD.tukey.test(y, trt, DError, SSError, alpha, group, main)
```

y: vetor com a variável-resposta;

trt: vetor com os tratamentos;

DError: grau de liberdade do resíduo;

SSError: soma de quadrados do resíduo;

alpha=0.05: significância do teste de Tukey; o *default* é 0,05;

group=TRUE: variável lógica e

main=NULL: título.

Teste de Duncan

A função `HSD.DUNCAN.test` permite a realização do teste de Tukey para comparação múltipla de médias e recebe 6 argumentos, nesta ordem:

```
HSD.DUNCAN.test(y, trt, DError, SSError, alpha, group, main)
```

y: vetor com a variável-resposta;

trt: vetor com os tratamentos;

DError: grau de liberdade do resíduo;

SSerror: soma de quadrados do resíduo;
 alpha=0.05: significância do teste de Duncan; o *default* é 0,05;
 group=TRUE: variável lógica e
 main=NULL: título.

Teste de Student-Newman-Keuls

A função `HSD.SNK.test` permite a realização do teste de SNK para comparação múltipla de médias e recebe 6 argumentos, nesta ordem:

```
HSD.SNK.test(y, trt, DError, SSerror, alpha, group, main)
```

y: vetor com a variável-resposta;
 trt: vetor com os tratamentos;
 DError: grau de liberdade do resíduo;
 SSerror: soma de quadrados do resíduo;
 alpha=0.05: significância do teste de SNK; o *default* é 0,05;
 group=TRUE: variável lógica e
 main=NULL: título.

Teste de Scott-Knott

A função `HSD.SCOTTKNOTT.test` permite a realização do teste de Tukey para comparação múltipla de médias e recebe 6 argumentos, nesta ordem:

```
HSD.SCOTTKNOTT.test(y, trt, DError, SSerror, alpha, group, main)
```

y: vetor com a variável-resposta;
 trt: vetor com os tratamentos;
 DError: grau de liberdade do resíduo;
 SSerror: soma de quadrados do resíduo;
 alpha=0.05: significância do teste de Scott-Knott; o *default* é 0,05;
 group=TRUE: variável lógica e
 main=NULL: título.

6.0.8 Rotinas

As rotinas programadas permitem analisar experimentos em delineamentos simples, em DIC, DBC e DQL, experimentos em esquema de fatorial duplo, em DIC e DBC, em esquema de fatorial duplo com um tratamento adicional (em DIC e DBC), em esquema de fatorial triplo, em DIC e DBC, em esquema de fatorial triplo com um tratamento adicional (em DIC e DBC) e em esquema de parcelas subdivididas em DIC e DBC, em uma só rodada; nomeadas, respectivamente, `dic()`, `dbc()`, `dql()`, `fat2.dic()`, `fat2.dbc()`, `fat2.ad.dic()`, `fat2.ad.dbc()`, `fat3.dic()`, `fat3.dbc()`, `fat3.ad.dic()`, `fat3.ad.dbc()`, `psub2.dic()` e `psub2.dbc()`.

Estas funções realizam o teste de normalidade de Shapiro-Wilk (excetuando apenas as funções `psub2.dic()` e `psub2.dbc()`), a análise de variância e comparação de médias, sendo que as médias dos tratamentos quantitativos são diferenciadas pelo ajuste de modelos sequenciais de regressão até o terceiro grau e as médias dos tratamentos qualitativos podem ser diferenciadas pelos seguintes testes de comparação múltipla: teste t (LSD), teste t com proteção de Bonferroni (LSDB), teste de Tukey, teste de Duncan, teste de Student-Newman-Keuls (SNK) e teste de Scott-Knott.

DIC simples

A função `dic()` (FERREIRA & CAVALCANTI, 2009) permite analisar DICs simples e recebe 6 argumentos, nesta ordem:

```
dic(trat, resp, quali, mcomp, sigT, sigF)
```

trat: vetor com os tratamentos;

resp: vetor com a variável-resposta;

quali=T: variável lógica, se *TRUE* (*default*), os tratamentos são designados como qualitativos, se *FALSE*, quantitativos;

mcomp='tukey': variável que permite escolher o teste de comparação múltipla; o *default* é o teste de Tukey, contudo tem-se como outras opções: o teste LSD (*'lsd'*), o teste LSDb (*'lsdb'*), o teste de Duncan (*'duncan'*), o teste de SNK (*'snk'*) e o teste de Scott-Knott (*'sk'*);

sigT: significância do teste de comparação múltipla de médias; o *default* é 0,05 (só válida para tratamentos qualitativos); e

sigF: significância do teste F da ANAVA; o *default* é 0,05.

A saída da função `dic()` pode ser observada a seguir, exemplificada por:

a) Adição de cinco porcentagens de farinha da polpa de yacon em dietas experimentais e seu efeito no índice glicêmico: ANAVA seguida do ajuste de modelos de regressão até o terceiro grau.

Quadro da análise de variância

	GL	SQ	QM	Fc	Pr>Fc
Tratamento	3	214.88	71.626	6.5212	0.0029622
Resíduo	20	219.67	10.984		
Total	23	434.55			

CV = 3.41 %

Teste de normalidade dos resíduos (Shapiro-Wilk)

p-valor: 0.9169705

De acordo com o teste de Shapiro-Wilk a 5% de significância, os resíduos podem ser considerados normais.

```

Ajuste de modelos polinomiais de regressão
-----
$'Modelo linear'
-----
      Estimativa Erro.padrão      tc p.valor
b0  100.2878      1.13200 88.59383 0.00000
b1   -0.4136      0.12102 -3.41775 0.00273

$'R2 do modelo linear'
[1] 0.5970766

$'Análise de variância do modelo linear'
      GL      SQ      QM      Fc p.valor
Efeito linear      1 128.29872 128.29872 11.68 0.00273
Desvios de Regressão 2  86.57943  43.28971  3.94 0.03605
Resíduos          20 219.67103  10.98355

-----
$'Modelo quadrático'
-----
      Estimativa Erro.padrão      tc p.valor
b0  101.5728      1.31874 77.02292 0.00000
b1   -1.1846      0.42355 -2.79681 0.01114
b2    0.0514      0.02706  1.89949 0.07202

$'R2 do modelo quadrático'
[1] 0.781504

$'Análise de variância do modelo quadrático'
      GL      SQ      QM      Fc p.valor
Efeito linear      1 128.29872 128.29872 11.68 0.00273
Efeito quadrático   1  39.62940  39.62940  3.61 0.07202
Desvios de Regressão 1  46.95003  46.95003  4.27 0.05187
Resíduos          20 219.67103  10.98355

-----
$'Modelo cúbico'
-----
      Estimativa Erro.padrão      tc p.valor
b0  102.19833      1.35299 75.53497 0.00000
b1   -3.14450      1.03828 -3.02858 0.00663
b2    0.42670      0.18353  2.32497 0.03071
b3   -0.01668      0.00807 -2.06750 0.05187

$'R2 do modelo cúbico'
[1] 1

$'Análise de variância do modelo cúbico'
      GL      SQ      QM      Fc p.valor
Efeito linear      1 128.29872 128.29872 11.68 0.00273
Efeito quadrático   1  39.62940  39.62940  3.61 0.07202
Efeito cúbico       1  46.95003  46.95003  4.27 0.05187
Desvios de Regressão 0  0.00000  0.00000  0      1
Resíduos          20 219.67103  10.98355

```

Figura 14: Saída da função `dic()`.

DBC simples

A função `dbc()` (FERREIRA; CAVALCANTI; NOGUEIRA, 2009-a) permite analisar DBCs simples e recebe 7 argumentos, nesta ordem:

```
dbc(trat, bloco, resp, quali, mcomp, sigT, sigF)
```

trat: vetor com os tratamentos;

bloco: vetor com os blocos;

resp: vetor com a variável-resposta;

quali=T: variável lógica, se *TRUE* (*default*), os tratamentos são designados como qualitativos, se *FALSE*, quantitativos;

mcomp='tukey': variável que permite escolher o teste de comparação múltipla; o *default* é o teste de Tukey, contudo tem-se como outras opções: o teste LSD ('lsd'), o teste LSDb ('lsdb'), o teste de Duncan ('duncan'), o teste de SNK ('snk') e o teste de Scott-Knott ('sk');

sigT: significância do teste de comparação múltipla de médias; o *default* é 0,05 (só válida para tratamentos qualitativos); e

sigF: significância do teste F da ANAVA; o *default* é 0,05.

A saída da função `dbc()` pode ser observada a seguir, exemplificada por:

a) Notas (de 1 a 9) para a aparência de cinco barras alimentícias avaliadas por 70 consumidores de barras de cereais: ANAVA seguida de teste t de Student (LSD).

```
-----
Quadro da análise de variância
-----
          GL      SQ      QM      Fc      Pr>Fc
Tratamento  4  720.38 180.096 71.156 0.00000000
Bloco        69  324.00   4.696   1.855 0.00025852
Resíduo      276  698.55   2.531
Total        349 1742.94
-----
CV = 29.14 %

-----
Teste de normalidade dos resíduos (Shapiro-Wilk)
p-valor:  0.6173908
De acordo com o teste de Shapiro-Wilk a 5% de significância, os
resíduos podem ser considerados normais.
-----

Teste t (LSD)
-----
Grupos  Tratamentos  Médias
a        D           6.657143
a        E           6.6
a        C           6.271429
b        B           4.871429
c        A           2.9
-----
```

Figura 15: Saída da função `dbc()`.

DQL simples

A função `dql()` (FERREIRA; CAVALCANTI; NOGUEIRA, 2009-b) permite analisar DQLs simples e recebe 8 argumentos, nesta ordem:

```
dql(trat, linha, coluna, resp, quali, mcomp, sigT, sigF)
```

trat: vetor com os tratamentos;

linha: vetor com as linhas;

coluna: vetor com as colunas;

resp: vetor com a variável-resposta;

quali=T: variável lógica, se *TRUE* (*default*), os tratamentos são designados como qualitativos, se *FALSE*, quantitativos;

mcomp='tukey': variável que permite escolher o teste de comparação múltipla; o *default* é o teste de Tukey, contudo tem-se como outras opções: o teste LSD (*'lsd'*), o teste LSDB (*'lsdb'*), o teste de Duncan (*'duncan'*), o teste de SNK (*'snk'*) e o teste de Scott-Knott (*'sk'*);

sigT: significância do teste de comparação múltipla de médias; o *default* é 0,05 (só válida para tratamentos qualitativos); e

sigF: significância do teste F da ANAVA; o *default* é 0,05.

A saída da função `dql()` pode ser observada a seguir, exemplificada por:

a) Sete forrageiras nativas e exóticas e sua produção de matéria seca (t/ha/corte): ANAVA seguida de teste de Duncan;

```

-----
Quadro da análise de variância
-----

```

	GL	SQ	QM	Fc	Pr>Fc
Tratamento	6	58.900	9.817	32.071	9.231e-12
Linha	6	3.009	0.501	1.638	0.171
Coluna	6	1.269	0.211	0.691	0.659
Resíduo	30	9.183	0.306		
Total	48	72.360			

```

-----
CV = 22.39 %
-----

Teste de normalidade dos resíduos (Shapiro-Wilk)
p-valor: 0.3272454
De acordo com o teste de Shapiro-Wilk a 5% de significância, os
resíduos podem ser considerados normais.
-----

Teste de Duncan
-----

```

Grupos	Tratamentos	Médias
a	A	4.4
b	B	3.6
c	C	2.8
d	D	2
d	E	1.9
de	F	1.4
e	G	1.2

```

-----

```

Figura 16: Saída da função `dql()`.

Fatorial duplo em DIC

A função `fat2.dic()` permite analisar DICs em fatorial duplo e recebe 8 argumentos, nesta ordem:

```
fat2.dic(fator1, fator2, resp, quali, mcomp, fac.names, sigT, sigF)
```

fator1: vetor com os níveis do fator 1;

fator2: vetor com os níveis do fator 2;

resp: vetor com a variável-resposta;

quali=c(T,T): variável lógica, se *TRUE* (*default*) na primeira posição, os níveis do fator 1 são designados como qualitativos, se *FALSE*, quantitativos; da mesma forma, a segunda posição é referente aos níveis do fator 2;

mcomp='tukey': variável que permite escolher o teste de comparação múltipla; o *default* é o teste de Tukey, contudo tem-se como outras opções: o teste LSD (*'lsd'*), o teste LSDB (*'lsdb'*), o teste de Duncan (*'duncan'*), o teste de SNK (*'snk'*) e o teste de Scott-Knott (*'sk'*);

fac.names=c('F1', 'F2'): permite nomear os fatores 1 e 2;

sigT: significância do teste de comparação múltipla de médias; o *default* é 0,05 (só válida para tratamentos qualitativos); e

sigF: significância do teste F da ANAVA; o *default* é 0,05.

A saída da função `fat2.dic()` pode ser observada a seguir, exemplificada por:

a) Compostagem de casca de café misturada ou não com esterco de bovinos (fator qualitativo) em quatro intervalos de revolvimento (fator quantitativo) e seu efeito na concentração de Zinco: ANAVA seguida de teste de Tukey.

```

-----
Legenda:
FATOR 1: Revolvimento
FATOR 2: Esterco
-----

Quadro da análise de variância
-----

```

	GL	SQ	QM	Fc	Pr>Fc
Revolvimento	3	220.5	73.5	0.606	0.62077
Esterco	1	20416.7	20416.7	168.269	0.00000
Revolvimento*Esterco	3	653.3	217.8	1.795	0.18870
Resíduo	16	1941.3	121.3		
Total	23	23231.8			

```

-----
CV = 12.75 %
-----

Teste de normalidade dos resíduos (Shapiro-Wilk)
p-valor: 0.6341772
De acordo com o teste de Shapiro-Wilk a 5% de significância, os
resíduos podem ser considerados normais.
-----

Interação não significativa: analisando os efeitos simples
-----

Revolvimento
De acordo com o teste F, as médias desse fator são
estatisticamente iguais.

  Níveis  Médias
1      10 90.16667
2      15 85.16667
3      20 82.16667
4       5 88.16667
-----

Esterco
Teste de Tukey
-----

Grupos Tratamentos Médias
a      com    115.5833
b      sem     57.25
-----

```

Figura 17: Saída da função fat2.dic().

Fatorial duplo em DBC

A função `fat2.dbc()` permite analisar DBCs em fatorial duplo e recebe 9 argumentos, nesta ordem:

```
fat2.dbc(fator1, fator2, bloco, resp, quali, mcomp, fac.names, sigT,
         sigF)
```

`fator1`: vetor com os níveis do fator 1;

`fator2`: vetor com os níveis do fator 2;

`bloco`: vetor com os blocos;

`resp`: vetor com a variável-resposta;

`quali=c(T,T)`: variável lógica, se *TRUE* (*default*) na primeira posição, os níveis do fator 1 são designados como qualitativos, se *FALSE*, quantitativos; da mesma forma, a segunda posição é referente aos níveis do fator 2;

`mcomp='tukey'`: variável que permite escolher o teste de comparação múltipla; o *default* é o teste de Tukey, contudo tem-se como outras opções: o teste LSD (`'lsd'`), o teste LSDB (`'lsdb'`), o teste de Duncan (`'duncan'`), o teste de SNK (`'snk'`) e o teste de Scott-Knott (`'sk'`);

`fac.names=c('F1','F2')`: permite nomear os fatores 1 e 2;

`sigT`: significância do teste de comparação múltipla de médias; o *default* é 0,05 (só válida para tratamentos qualitativos); e

`sigF`: significância do teste F da ANAVA; o *default* é 0,05.

A saída da função `fat2.dbc()` pode ser observada a seguir, exemplificada por:

a) Vinte provadores de cada gênero avaliando quatro amostras das diferentes formulações das barras alimentícias: ANAVA.


```

-----
Legenda:
FATOR 1: Amostras
FATOR 2: Gênero
-----

Quadro da análise de variância
-----

```

	GL	SQ	QM	Fc	Pr>Fc
Bloco	19	97.82	5.1484	1.55116	0.07832
Amostras	3	19.37	6.4562	1.94522	0.12537
Gênero	1	7.66	7.6562	2.30677	0.13118
Amostras*Gênero	3	3.92	1.3062	0.39356	0.75783
Resíduo	133	441.43	3.3190		
Total	159	570.19			

```

-----
CV = 27.58 %
-----

Teste de normalidade dos resíduos (Shapiro-Wilk)
p-valor: 0.00542845
ATENÇÃO: a 5% de significância, os resíduos não podem ser
considerados normais!
-----

Interação não significativa: analisando os efeitos simples
-----

Amostras
De acordo com o teste F, as médias desse fator são
estatisticamente iguais.
  Níveis Médias
1   10g  6.850
2   15g  6.975
3   15t  6.075
4   20t  6.525
-----

Gênero
De acordo com o teste F, as médias desse fator são
estatisticamente iguais.
  Níveis Médias
1   F 6.8250
2   M 6.3875
-----

```

Figura 18: Saída da função fat2.dbc().

Fatorial duplo com um tratamento adicional em DIC

A função `fat2.ad.dic()` permite analisar DICs em fatorial duplo com um tratamento adicional e recebe 10 argumentos, nesta ordem:

```
fat2.ad.dic(fator1, fator2, repet, resp, repsAd, quali, mcomp, fac.names,
            sigT, sigF)
```

fator1: vetor com os níveis do fator 1;

fator2: vetor com os níveis do fator 2;

repet: vetor com as repetições;

resp: vetor com a variável-resposta;

repsAd: vetor com a variável-resposta do tratamento adicional;

quali=`c(T,T)`: variável lógica, se *TRUE* (*default*) na primeira posição, os níveis do fator 1 são designados como qualitativos, se *FALSE*, quantitativos; da mesma forma, a segunda posição é referente aos níveis do fator 2;

mcomp=`'tukey'`: variável que permite escolher o teste de comparação múltipla; o *default* é o teste de Tukey, contudo tem-se como outras opções: o teste LSD (`'lsd'`), o teste LSDb (`'lsdb'`), o teste de Duncan (`'duncan'`), o teste de SNK (`'snk'`) e o teste de Scott-Knott (`'sk'`);

fac.names=`c('F1', 'F2')`: permite nomear os fatores 1 e 2;

sigT: significância do teste de comparação múltipla de médias; o *default* é 0,05 (só válida para tratamentos qualitativos); e

sigF: significância do teste F da ANAVA; o *default* é 0,05.

A saída da função `fat2.ad.dic()` pode ser observada a seguir, exemplificada por:

a) Compostagem da borra resultante da extração do biodiesel em quatro proporções (fator quantitativo) tendo como inoculante o esterco de bovinos ou a torta de mamona (fator qualitativo) e mais um tratamento adicional (testemunha) sem inoculante e sem borra; avaliando o efeito na biomassa fresca de sorgo: ANAVA seguida de teste de Tukey para o fator qualitativo Inoculante.

 Legenda:

FATOR 1: Inoculante

FATOR 2: Borra

 Quadro da análise de variância

	GL	SQ	QM	Fc	Pr>Fc
Inoculante	1	11.97094	11.97094	44.9491	0
Borra	3	1.55215	0.51738	1.9427	0.1589
Inoculante*Borra	3	2.38681	0.79560	2.9874	0.0585
Ad vs Fatorial	1	5.53280	5.53280	20.7748	2e-04
Resíduo	18	4.79380	0.26632		
Total	26	26.23650	1.00910		

 Teste de normalidade dos resíduos (Shapiro-Wilk)

p-valor: 0.05468962

De acordo com o teste de Shapiro-Wilk a 5% de significância, os resíduos podem ser considerados normais.

 Contraste do tratamento adicional com o fatorial

Médias

Adicional 0.910000 a

Fatorial 2.350417 b

 Interação não significativa: analisando os efeitos simples

Inoculante

Teste de Tukey

Grupos Tratamentos Médias

a mamona 3.056667

b esterco 1.644167

Borra

De acordo com o teste F, as médias desse fator são estatisticamente iguais.

	Níveis	Médias
1	10	2.780000
2	15	2.293333
3	20	2.191667
4	5	2.136667

Figura 19: Saída da função fat2.ad.dic().

Fatorial duplo com um tratamento adicional em DBC

A função `fat2.ad.dbc()` permite analisar DBCs em fatorial duplo com um tratamento adicional e recebe 10 argumentos, nesta ordem:

```
fat2.ad.dbc(fator1, fator2, bloco, resp, respAd, quali, mcomp, fac.names,
            sigT, sigF)
```

`fator1`: vetor com os níveis do fator 1;

`fator2`: vetor com os níveis do fator 2;

`bloco`: vetor com os blocos;

`resp`: vetor com a variável-resposta;

`respAd`: vetor com a variável-resposta do tratamento adicional;

`quali=c(T,T)`: variável lógica, se *TRUE* (*default*) na primeira posição, os níveis do fator 1 são designados como qualitativos, se *FALSE*, quantitativos; da mesma forma, a segunda posição é referente aos níveis do fator 2;

`mcomp='tukey'`: variável que permite escolher o teste de comparação múltipla; o *default* é o teste de Tukey, contudo tem-se como outras opções: o teste LSD (`'lsd'`), o teste LSDb (`'lsdb'`), o teste de Duncan (`'duncan'`), o teste de SNK (`'snk'`) e o teste de Scott-Knott (`'sk'`);

`fac.names=c('F1','F2')`: permite nomear os fatores 1 e 2;

`sigT`: significância do teste de comparação múltipla de médias; o *default* é 0,05 (só válida para tratamentos qualitativos); e

`sigF`: significância do teste F da ANAVA; o *default* é 0,05.

A saída da função `fat2.ad.dbc()` pode ser observada a seguir, exemplificada por:

a) Dados simulados que apresentam dois níveis em cada fator e três blocos: ANAVA.

Legenda:

FATOR 1: Fator A

FATOR 2: Fator B

Quadro da análise de variância

	GL	SQ	QM	Fc	Pr>Fc
Bloco	2	2.70400	1.35200	4.4768	0.0496
Fator A	1	0.48000	0.48000	1.5894	0.2429
Fator B	1	0.16333	0.16333	0.5408	0.4831
Fator A*Fator B	1	0.12000	0.12000	0.3974	0.546
Ad vs Fatorial	1	0.24067	0.24067	0.7969	0.3981
Resíduo	8	2.41600	0.30200		
Total	14	6.12400	0.43743		

Teste de normalidade dos resíduos (Shapiro-Wilk)

p-valor: 0.3915032

De acordo com o teste de Shapiro-Wilk a 5% de significância, os resíduos podem ser considerados normais.

Contraste do tratamento adicional com o fatorial

De acordo com o teste F, as médias dos dois grupos são estatisticamente iguais.

Médias

Adicional 10.53333

Fatorial 10.21667

Interação não significativa: analisando os efeitos simples

Fator A

De acordo com o teste F, as médias desse fator são estatisticamente iguais.

Níveis Médias

1 1 10.41667

2 2 10.01667

Fator B

De acordo com o teste F, as médias desse fator são estatisticamente iguais.

Níveis Médias

1 1 10.10000

2 2 10.33333

Figura 20: Saída da função `fat2.ad.dbc()`.

Fatorial triplo em DIC

A função `fat3.dic()` permite analisar DICs em fatorial triplo e recebe 9 argumentos, nesta ordem:

```
fat3.dic(fator1, fator2, fator3, resp, quali, mcomp, fac.names, sigT,
        sigF)
```

`fator1`: vetor com os níveis do fator 1;

`fator2`: vetor com os níveis do fator 2;

`fator3`: vetor com os níveis do fator 3;

`resp`: vetor com a variável-resposta;

`quali=c(T,T,T)`: variável lógica, se *TRUE* (*default*) na primeira posição, os níveis do fator 1 são designados como qualitativos, se *FALSE*, quantitativos; da mesma forma, a segunda posição é referente aos níveis do fator 2 e a terceira posição aos níveis do fator 3;

`mcomp='tukey'`: variável que permite escolher o teste de comparação múltipla; o *default* é o teste de Tukey, contudo tem-se como outras opções: o teste LSD (`'lsd'`), o teste LSDB (`'lsdb'`), o teste de Duncan (`'duncan'`), o teste de SNK (`'snk'`) e o teste de Scott-Knott (`'sk'`);

`fac.names=c('F1','F2','F3')`: permite nomear os fatores 1, 2 e 3;

`sigT`: significância do teste de comparação múltipla de médias; o *default* é 0,05 (só válida para tratamentos qualitativos); e

`sigF`: significância do teste F da ANAVA; o *default* é 0,05.

A saída da função `fat3.dic()` pode ser observada a seguir, exemplificada por:

a) Dados simulados que apresentam dois níveis em cada fator e três repetições: ANAVA, seguida do desdobramento da interação $FatorA * FatorB$ com o teste de Duncan.

```

-----
Legenda:
FATOR 1:  Fator A
FATOR 2:  Fator B
FATOR 3:  Fator C
-----

```

```

-----
Quadro da análise de variância
-----

```

	GL	SQ	QM	Fc	Pr>Fc
Fator A	1	0.51042	0.51042	0.8362	0.3741
Fator B	1	0.51042	0.51042	0.8362	0.3741
Fator C	1	0.05042	0.05042	0.0826	0.7775
Fator A*Fator B	1	2.87042	2.87042	4.7024	0.0455
Fator A*Fator C	1	0.12042	0.12042	0.1973	0.6629
Fator B*Fator C	1	0.40042	0.40042	0.656	0.4299
Fator A*Fator B*Fator C	1	0.02042	0.02042	0.0334	0.8572
Resíduo	16	9.76667	0.61042		
Total	23	14.24958	0.61955		

```

-----
Teste de normalidade dos resíduos (Shapiro-Wilk)

```

p-valor: 0.6752551

De acordo com o teste de Shapiro-Wilk a 5% de significância, os resíduos podem ser considerados normais.

```

-----
Interação Fator A*Fator B  significativa: desdobrando a
interação
-----

```

```

-----
Desdobrando  Fator A  dentro de cada nível de  Fator B
-----

```

```

-----
Quadro da análise de variância
-----

```

	GL	SQ	QM	Fc	Pr>Fc
Fator B:Fator A 1	1	2.90083	2.90083	4.7522	0.0445
Fator B:Fator A 2	1	0.48000	0.48000	0.7863	0.3883
Resíduo	16	9.76667	0.61042		


```

Fator A dentro do nível 1 de Fator B
-----
Teste t de Bonferroni (LSD protegido)
-----
Grupos  Tratamentos  Médias
a        1          10.41667
b        2           9.433333
-----

Fator A dentro do nível 2 de Fator B

De acordo com o teste F, as médias desse fator são
estatisticamente iguais.
      Níveis      Médias
1         1    10.01667
2         2    10.41667
-----

Desdobrando Fator B dentro de cada nível de Fator A
-----
-----
Quadro da análise de variância
-----
      GL      SQ      QM      Fc  Pr>Fc
Fator A:Fator B 1  1 0.48000 0.48000 0.7863 0.3883
Fator A:Fator B 2  1 2.90083 2.90083 4.7522 0.0445
Resíduo          16 9.76667 0.61042
-----

Fator B dentro do nível 1 de Fator A

De acordo com o teste F, as médias desse fator são
estatisticamente iguais.
      Níveis      Médias
1         1    10.41667
2         2    10.01667
-----

Fator B dentro do nível 2 de Fator A
-----
Teste t de Bonferroni (LSD protegido)
-----
Grupos  Tratamentos  Médias
a        2          10.41667
b        1           9.433333
-----

```

Figura 21: Saída da função `fat3.dic()`.

Fatorial triplo em DBC

A função `fat3.dbc()` permite analisar DBCs em fatorial triplo e recebe 10 argumentos, nesta ordem:

```
fat3.dbc(fator1, fator2, fator3, bloco, resp, quali, mcomp, fac.names,
         sigT, sigF)
```

`fator1`: vetor com os níveis do fator 1;

`fator2`: vetor com os níveis do fator 2;

`fator3`: vetor com os níveis do fator 3;

`bloco`: vetor com os blocos;

`resp`: vetor com a variável-resposta;

`quali=c(T,T,T)`: variável lógica, se *TRUE* (*default*) na primeira posição, os níveis do fator 1 são designados como qualitativos, se *FALSE*, quantitativos; da mesma forma, a segunda posição é referente aos níveis do fator 2 e a terceira posição aos níveis do fator 3;

`mcomp='tukey'`: variável que permite escolher o teste de comparação múltipla; o *default* é o teste de Tukey, contudo tem-se como outras opções: o teste LSD (`'lsd'`), o teste LSDb (`'lsdb'`), o teste de Duncan (`'duncan'`), o teste de SNK (`'snk'`) e o teste de Scott-Knott (`'sk'`);

`fac.names=c('F1','F2','F3')`: permite nomear os fatores 1, 2 e 3;

`sigT`: significância do teste de comparação múltipla de médias; o *default* é 0,05 (só válida para tratamentos qualitativos); e

`sigF`: significância do teste F da ANAVA; o *default* é 0,05.

A saída da função `fat3.dbc()` pode ser observada a seguir, exemplificada por:

a) Dados simulados que apresentam dois níveis em cada fator e três blocos: ANAVA.

Legenda:

FATOR 1: Fator A

FATOR 2: Fator B

FATOR 3: Fator C

Quadro da análise de variância

	GL	SQ	QM	Fc	Pr>Fc
Bloco	2	0.85083	0.42542	0.668	0.5283
Fator A	1	0.51042	0.51042	0.8015	0.3858
Fator B	1	0.51042	0.51042	0.8015	0.3858
Fator C	1	0.05042	0.05042	0.0792	0.7825
Fator A*Fator B	1	2.87042	2.87042	4.5072	0.0521
Fator A*Fator C	1	0.12042	0.12042	0.1891	0.6703
Fator B*Fator C	1	0.40042	0.40042	0.6288	0.441
Fator A*Fator B*Fator C	1	0.02042	0.02042	0.0321	0.8605
Resíduo	14	8.91583	0.63685		
Total	21	14.24958	0.67855		

Teste de normalidade dos resíduos (Shapiro-Wilk)

p-valor: 0.6743789

De acordo com o teste de Shapiro-Wilk a 5% de significância, os resíduos podem ser considerados normais.

Interação não significativa: analisando os efeitos simples

Fator A

De acordo com o teste F, as médias desse fator são estatisticamente iguais.

Níveis	Médias
1	10.21667
2	9.92500

Fator B

De acordo com o teste F, as médias desse fator são estatisticamente iguais.

Níveis	Médias
1	9.92500
2	10.21667

Fator C

De acordo com o teste F, as médias desse fator são estatisticamente iguais.

Níveis	Médias
1	10.02500
2	10.11667

Figura 22: Saída da função fat3.dbc().

Fatorial triplo com um tratamento adicional em DIC

A função `fat3.ad.dic()` permite analisar DICs em fatorial triplo com um tratamento adicional e recebe 11 argumentos, nesta ordem:

```
fat3.ad.dic(fator1, fator2, fator3, repet, resp, repsAd, quali, mcomp,
            fac.names, sigT, sigF)
```

fator1: vetor com os níveis do fator 1;

fator2: vetor com os níveis do fator 2;

fator3: vetor com os níveis do fator 3;

repet: vetor com as repetições;

resp: vetor com a variável-resposta;

repsAd: vetor com a variável-resposta do tratamento adicional;

quali=c(T,T,T): variável lógica, se *TRUE* (*default*) na primeira posição, os níveis do fator 1 são designados como qualitativos, se *FALSE*, quantitativos; da mesma forma, a segunda posição é referente aos níveis do fator 2 e a terceira posição aos níveis do fator 3;

mcomp='tukey': variável que permite escolher o teste de comparação múltipla; o *default* é o teste de Tukey, contudo tem-se como outras opções: o teste LSD (*'lsd'*), o teste LSDB (*'lsdb'*), o teste de Duncan (*'duncan'*), o teste de SNK (*'snk'*) e o teste de Scott-Knott (*'sk'*);

fac.names=c('F1','F2','F3'): permite nomear os fatores 1, 2 e 3;

sigT: significância do teste de comparação múltipla de médias; o *default* é 0,05 (só válida para tratamentos qualitativos); e

sigF: significância do teste F da ANAVA; o *default* é 0,05.

A saída da função `fat3.ad.dic()` pode ser observada a seguir, exemplificada por:

a) Dados simulados que apresentam dois níveis em cada fator e três repetições: ANAVA, seguida de teste de SNK.

 Legenda:

FATOR 1: Fator A

FATOR 2: Fator B

FATOR 3: Fator C

 Quadro da análise de variância

	GL	SQ	QM	Fc	Pr>Fc
Fator A	1	0.51042	0.51042	0.8184	0.3776
Fator B	1	0.51042	0.51042	0.8184	0.3776
Fator C	1	0.05042	0.05042	0.0808	0.3776
Fator A*Fator B	1	2.87042	2.87042	4.6022	0.0458
Fator A*Fator C	1	0.12042	0.12042	0.1931	0.6656
Fator B*Fator C	1	0.40042	0.40042	0.642	0.4334
Fator A*Fator B*Fator C	1	0.02042	0.02042	0.0327	0.8584
Ad vs Fatorial	1	0.49116	0.49116	0.7875	0.3866
Resíduo	18	11.22667	0.62370		
Total	26	16.20074	0.62311		

 Teste de normalidade dos resíduos (Shapiro-Wilk)

p-valor: 0.6241183

De acordo com o teste de Shapiro-Wilk a 5% de significância, os resíduos podem ser considerados normais.

 Contraste do tratamento adicional com o fatorial

De acordo com o teste F, as médias dos dois grupos são estatisticamente iguais.

Médias

Adicional 10.50000

Fatorial 10.07083

 Interação Fator A*Fator B significativa: desdobrando a interação

 Desdobrando Fator A dentro de cada nível de Fator B

 Quadro da análise de variância

	GL	SQ	QM	Fc	Pr>Fc
Fator B:Fator A 1	1	2.90083	2.90083	4.651	0.0448
Fator B:Fator A 2	1	0.48000	0.48000	0.7696	0.3919
Resíduo	18	11.22667	0.62370		

Fator A dentro do nível 1 de Fator B

 Teste de Student-Newman-Keuls (SNK)

Grupos	Tratamentos	Médias
a	1	10.41667
b	2	9.433333

Fator A dentro do nível 2 de Fator B

De acordo com o teste F, as médias desse fator são estatisticamente iguais.

	Níveis	Médias
1	1	10.01667
2	2	10.41667

Desdobrando Fator B dentro de cada nível de Fator A

 Quadro da análise de variância

	GL	SQ	QM	Fc	Pr>Fc
Fator A:Fator B 1	1	0.48000	0.48000	0.7696	0.3919
Fator A:Fator B 2	1	2.90083	2.90083	4.651	0.0448
Resíduo	18	11.22667	0.62370		

Fator B dentro do nível 1 de Fator A

De acordo com o teste F, as médias desse fator são estatisticamente iguais.

	Níveis	Médias
1	1	10.41667
2	2	10.01667

Fator B dentro do nível 2 de Fator A

 Teste de Student-Newman-Keuls (SNK)

Grupos	Tratamentos	Médias
a	2	10.41667
b	1	9.433333

Figura 23: Saída da função `fat3.ad.dic()`.

Fatorial triplo com um tratamento adicional em DBC

A função `fat3.ad.dbc()` permite analisar DBCs em fatorial triplo com um tratamento adicional e recebe 11 argumentos, nesta ordem:

```
fat3.ad.dbc(fator1, fator2, fator3, bloco, resp, respAd, quali, mcomp,
            fac.names, sigT, sigF)
```

fator1: vetor com os níveis do fator 1;

fator2: vetor com os níveis do fator 2;

fator3: vetor com os níveis do fator 3;

bloco: vetor com os blocos;

resp: vetor com a variável-resposta;

respAd: vetor com a variável-resposta do tratamento adicional;

quali=c(T,T,T): variável lógica, se *TRUE* (*default*) na primeira posição, os níveis do fator 1 são designados como qualitativos, se *FALSE*, quantitativos; da mesma forma, a segunda posição é referente aos níveis do fator 2 e a terceira posição aos níveis do fator 3;

mcomp='tukey': variável que permite escolher o teste de comparação múltipla; o *default* é o teste de Tukey, contudo tem-se como outras opções: o teste LSD (*'lsd'*), o teste LSDB (*'lsdb'*), o teste de Duncan (*'duncan'*), o teste de SNK (*'snk'*) e o teste de Scott-Knott (*'sk'*);

fac.names=c('F1','F2','F3'): permite nomear os fatores 1, 2 e 3;

sigT: significância do teste de comparação múltipla de médias; o *default* é 0,05 (só válida para tratamentos qualitativos); e

sigF: significância do teste F da ANAVA; o *default* é 0,05.

A saída da função `fat3.ad.dbc()` pode ser observada a seguir, exemplificada por:

a) Dados simulados que apresentam dois níveis em cada fator e três blocos: ANAVA, seguida de teste de Tukey.

 Legenda:

FATOR 1: Fator A

FATOR 2: Fator B

FATOR 3: Fator C

 Quadro da análise de variância

	GL	SQ	QM	Fc	Pr>Fc
Bloco	2	1.58296	0.79148	1.3132	0.2964
Fator A	1	0.51042	0.51042	0.8468	0.3711
Fator B	1	0.51042	0.51042	0.8468	0.3711
Fator C	1	0.05042	0.05042	0.0836	0.3711
Fator A*Fator B	1	2.87042	2.87042	4.7623	0.0443
Fator A*Fator C	1	0.12042	0.12042	0.1998	0.6609
Fator B*Fator C	1	0.40042	0.40042	0.6643	0.427
Fator A*Fator B*Fator C	1	0.02042	0.02042	0.0339	0.8563
Ad vs Fatorial	1	0.49116	0.49116	0.8149	0.3801
Resíduo	16	9.64370	0.60273		
Total	26	16.20074	0.62311		

 Teste de normalidade dos resíduos (Shapiro-Wilk)

p-valor: 0.7374966

De acordo com o teste de Shapiro-Wilk a 5% de significância, os resíduos podem ser considerados normais.

 Contraste do tratamento adicional com o fatorial

De acordo com o teste F, as médias dos dois grupos são estatisticamente iguais.

Médias

Adicional 10.50000

Fatorial 10.07083

 Interação Fator A*Fator B significativa: desdobrando a interação

 Desdobrando Fator A dentro de cada nível de Fator B

 Quadro da análise de variância

	GL	SQ	QM	Fc	Pr>Fc
Fator B:Fator A 1	1	2.90083	2.90083	4.8128	0.0434
Fator B:Fator A 2	1	0.48000	0.48000	0.7964	0.3854

```

Fator A dentro do nível 1 de Fator B
-----
Teste de Tukey
-----
Grupos Tratamentos Médias
a      1      10.41667
b      2      9.433333
-----

Fator A dentro do nível 2 de Fator B

De acordo com o teste F, as médias desse fator são
estatisticamente iguais.
      Níveis Médias
1      1      10.01667
2      2      10.41667
-----

Desdobrando Fator B dentro de cada nível de Fator A
-----
-----
Quadro da análise de variância
-----
      GL      SQ      QM      Fc      Pr>Fc
Fator A:Fator B 1  1 0.48000 0.48000 0.7964 0.3854
Fator A:Fator B 2  1 2.90083 2.90083 4.8128 0.0434
Resíduo          16 9.64370 0.60273
-----

Fator B dentro do nível 1 de Fator A

De acordo com o teste F, as médias desse fator são
estatisticamente iguais.
      Níveis Médias
1      1      10.41667
2      2      10.01667
-----

Fator B dentro do nível 2 de Fator A
-----
Teste de Tukey
-----
Grupos Tratamentos Médias
a      2      10.41667
b      1      9.433333
-----

```

Figura 24: Saída da função `fat3.ad.dbc()`.

Esquema de parcelas subdividas em DIC

A função `psub2.dic()` permite analisar DICs em esquema de parcelas subdividas e recebe 9 argumentos, nesta ordem:

```
psub2.dic(fator1, fator2, repet, resp, quali, mcomp, fac.names, sigT,
          sigF)
```

fator1: vetor com os níveis do fator 1;

fator2: vetor com os níveis do fator 2;

repet: vetor com as repetições;

resp: vetor com a variável-resposta;

quali=c(T,T): variável lógica, se *TRUE* (*default*) na primeira posição, os níveis do fator 1 são designados como qualitativos, se *FALSE*, quantitativos; da mesma forma, a segunda posição é referente aos níveis do fator 2;

mcomp='tukey': variável que permite escolher o teste de comparação múltipla; o *default* é o teste de Tukey, contudo tem-se como outras opções: o teste LSD (*'lsd'*), o teste LSDb (*'lsdb'*), o teste de Duncan (*'duncan'*), o teste de SNK (*'snk'*) e o teste de Scott-Knott (*'sk'*);

fac.names=c('F1', 'F2'): permite nomear os fatores 1 e 2;

sigT: significância do teste de comparação múltipla de médias; o *default* é 0,05 (só válida para tratamentos qualitativos); e

sigF: significância do teste F da ANAVA; o *default* é 0,05.

A saída da função `psub2.dic()` pode ser observada a seguir, exemplificada por:

a) Efeito, no pH do solo, do pisoteio de animais bovinos em cinco coberturas vegetais (fator qualitativo), analisadas em duas profundidades (fator qualitativo): ANAVA seguida de teste de Tukey para os fatores qualitativos Cobertura vegetal e Profundidade.


```

-----
Legenda:
FACTOR 1 (parcela): Cobertura
FACTOR 2 (subparcela): Profundidade
-----

Quadro da análise de variância
-----

```

	GL	SQ	QM	Fc	Pr(>Fc)
Cobertura	5	2.684167	0.536833	13.365145	0.003336
Erro a	6	0.241000	0.040167		
Profundidade	1	0.100833	0.100833	11.245353	0.002174
Cobertura*Profundidade	5	0.064167	0.012833	1.431227	0.241734
Erro b	30	0.269000	0.008967		
Total	47	3.359167			

```

-----
CV 1 = 3.743183 %
CV 2 = 1.768576 %

Interação não significativa: analisando os efeitos simples
-----

Cobertura
Teste de Tukey
-----

```

Grupos	Tratamentos	Médias
a	T1	5.6625
ab	T6	5.6125
ab	T2	5.375
abc	T3	5.275
bc	T4	5.2375
c	T5	4.9625

```

-----

Profundidade
Teste de Tukey
-----

```

Grupos	Tratamentos	Médias
a	1	5.4
b	2	5.308333

```

-----

```

Figura 25: Saída da função `psub2.dic()`.

Esquema de parcelas subdividas em DBC

A função `psub2.dbc()` permite analisar DBCs em esquema de parcelas subdividas e recebe 9 argumentos, nesta ordem:

```
psub2.dbc(fator1, fator2, bloco, resp, quali, mcomp, fac.names, sigT,
          sigF)
```

fator1: vetor com os níveis do fator 1;

fator2: vetor com os níveis do fator 2;

bloco: vetor com os blocos;

resp: vetor com a variável-resposta;

quali=c(T,T): variável lógica, se *TRUE* (*default*) na primeira posição, os níveis do fator 1 são designados como qualitativos, se *FALSE*, quantitativos; da mesma forma, a segunda posição é referente aos níveis do fator 2;

mcomp='tukey': variável que permite escolher o teste de comparação múltipla; o *default* é o teste de Tukey, contudo tem-se como outras opções: o teste LSD (*'lsd'*), o teste LSDb (*'lsdb'*), o teste de Duncan (*'duncan'*), o teste de SNK (*'snk'*) e o teste de Scott-Knott (*'sk'*);

fac.names=c('F1','F2'): permite nomear os fatores 1 e 2;

sigT: significância do teste de comparação múltipla de médias; o *default* é 0,05 (só válida para tratamentos qualitativos); e

sigF: significância do teste F da ANAVA; o *default* é 0,05.

A saída da função `psub2.dbc()` pode ser observada a seguir, exemplificada por:

a) Dados simulados que apresentam dois níveis em cada fator e três blocos: ANAVA.

```

-----
Legenda:
FATOR 1 (parcela): Fator A
FATOR 2 (subparcela): Fator B
-----

Quadro da análise de variância
-----

```

	GL	SQ	QM	Fc	Pr(>Fc)
Fator A	1	0.4800	0.48000	12.000	0.07418 .
Bloco	2	3.2267	1.61333	40.333	0.02419 *
Erro a	2	0.0800	0.04000		
Fator B	1	0.1633	0.16333	0.366	0.57800
Fator A*Fator B	1	0.1200	0.12000	0.269	0.63159
Erro b	4	1.7867	0.44667		
Total	11	5.8567			

```

-----
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
-----

CV 1 = 1.957586 %
CV 2 = 6.541578 %

Interação não significativa: analisando os efeitos simples
-----

Fator A
De acordo com o teste F, as médias desse fator são
estatisticamente iguais.
  Níveis  Médias
1         1 10.41667
2         2 10.01667
-----

Fator B
De acordo com o teste F, as médias desse fator são
estatisticamente iguais.
  Níveis  Médias
1         1 10.10000
2         2 10.33333
-----

```

Figura 26: Saída da função psub2.dbc().

6.0.9 Pacote

Por fim, criou-se um pacote, ou seja, uma biblioteca para comportar as funções programadas, que foi nomeado *ExpDes* (*Experimental Designs*). Este pacote, após instalado no software R, deve ser carregado no momento do uso e então as funções podem ser executadas em apenas uma rodada (apenas uma linha de comando).

7 Difusão de Tecnologia

7.1 Fases de Teste e Divulgação

A partir da primeira compilação do pacote *ExpDes*, ainda com poucas funções, este foi utilizado como ferramenta na disciplina "Planejamento e Análise de Experimentos", juntamente com o software Sisvar, para os cursos de Biotecnologia, Biomedicina e Matemática da Universidade Federal de Alfenas, durante o ano de 2010 (primeiro e segundo semestres).

A biblioteca *ExpDes* foi divulgada no dia 5 de novembro de 2010 na X Semana da Matemática e II Semana da Estatística da Universidade Federal de Ouro Preto (UFOP), Campus Ouro Preto.

Este período de teste tem o intuito de encontrar erros (*bugs*), verificar a aceitação do pacote e também analisar as possíveis críticas; para que, desta forma, melhorias possam ser feitas. Esta fase deve perdurar aproximadamente até o ano de 2012, para que haja tempo suficiente para um aperfeiçoamento da biblioteca de funções.

As funções do pacote estão sendo apresentadas separadamente em eventos científicos, desde eventos regionais a congressos internacionais. Algumas já foram apresentadas:

- `dic()`:

54^aReunião Anual Da Região Brasileira Da Sociedade Internacional De Biometria (RBRAS)/13^o Simpósio De Estatística Aplicada À Experimentação Agronômica (SEAGRO), em julho de 2009.

- `dbc()`:

II Jornada Científica Da Universidade Federal De Alfenas-MG, em setembro de 2009.

- `dq1()`:

XVIII Congresso De Pós-Graduação Da Universidade Federal De Lavras, em outubro de 2009.

Outras duas se encontram em um resumo aceito para apresentação na *XXVth International Biometric Conference* na Universidade Federal de Santa Catarina no dia 10 de dezembro de 2010: `psub2.dic()` e `psub2.dbc()`.

Está sendo escrito um artigo científico sobre todas funções programadas e a biblioteca que as contém (*ExpDes*).

7.2 Propriedade Intelectual

Com a intenção de proteger os direitos autorais do pacote *ExpDes*, foi procurado o Núcleo de Inovação e Propriedade Intelectual da Unifal-MG para orientações sobre o registro de "Programa de Computador" no Instituto Nacional de Propriedade Industrial (INPI). O processo está em andamento, contudo os autores vão disponibilizar o pacote de forma inteiramente gratuita, mantendo o código das funções aberto, conforme a filosofia do software R.

8 Conclusões

A biblioteca de funções *ExpDes* foi criada com sucesso. Desta forma, para todos os delineamentos experimentais e esquemas de análise propostos neste trabalho, a análise de variância e o teste de comparação múltipla de médias ou ajustes de modelos de regressão são realizados em uma só rodada, o que torna esse procedimento mais rápido, prático e de fácil compreensão principalmente para usuários não estatísticos.

9 Referências bibliográficas

- BANZATTO, D. A.; KRONKA, S. N. *Experimentação Agrícola*. Jaboticabal: FUNEP. 2006. 237p.
- COMASTRI FILHO, J. A. *Avaliação de espécies de forrageiras nativas e exóticas na sub-região dos paiaguás no pantanal mato-grossense*. Pesq. Agropec. Bras., Brasília, v.29, n.6, p. 971-978, jun. 1994.
- DIAS, L. A. dos S.; BARROS, W. S. *Biometria Experimental*. Viçosa: UFV. 2009. 408p.
- DRAPER, N. R.; SMITH, H. *Applied Regression Analysis*. 3ª ed. New York: J. Wiley. 1998. 706p.
- FERREIRA, D. F. *SISVAR: Um programa para análises e ensino de estatística*. Revista Symposium. Lavras, v.6, p. 36-41, 2008
- FERREIRA, D. F. *Estatística Básica*. Lavras: Editora UFLA, 2005. 664 p.
- FERREIRA, E. B.; CAVALCANTI, P. P. *Função em código R para analisar experimentos em DIC simples, em uma só rodada*. In: REUNIÃO ANUAL DA REGIÃO BRASILEIRA DA SOCIEDADE INTERNACIONAL DE BIOMETRIA, 54./SIMPÓSIO DE ESTATÍSTICA APLICADA À EXPERIMENTAÇÃO AGRONÔMICA, 13., 2009, São Carlos. *Programas e resumos...* São Carlos, SP: UFSCar, 2009. p. 1-5.
- FERREIRA, E. B.; CAVALCANTI, P. P.; NOGUEIRA D. A. *Função em código R para analisar experimentos em DBC simples, em uma só rodada*. In: JORNADA CIENTÍFICA DA UNIVERSIDADE FEDERAL DE ALFENAS-MG, 2., 2009, Alfenas. *Resumos...* Alfenas: Unifal-MG, 2009-a.
- FERREIRA, E. B.; CAVALCANTI, P. P.; NOGUEIRA D. A. *Função em código R para analisar experimentos em DQL simples, em uma só rodada*. In: CONGRESSO DE PÓS-GRADUAÇÃO DA UNIVERSIDADE FEDERAL DE LAVRAS, 18., 2009, Lavras. *Resumos...* Lavras: UFLA, 2009-b.
- GOMES, F. P. *Curso de Estatística Experimental*. 15ª ed. Piracicaba: ESALQ/USP. 2009. 451p.
- GOMES, F. P.; GARCIA, C.H. *Estatística Aplicada a Experimentos Agronômicos e Florestais - Exposição com Exemplos e Orientações para Uso de Aplicativos*. Piracicaba: ESALQ/USP. 2002. 309p.

GUERRA, A. R. *Atributos de Solo sob Coberturas Vegetais em Sistema Silvopastoril em Lavras - MG*. 2010. 141p. Dissertação (Mestrado em Engenharia Florestal) - Universidade Federal de Lavras, UFLA, Lavras, 2010.

HEALY, M. J. R. *The analysis of a factorial experiment with additional treatments*. Journal of Agricultural Science, Cambridge, v. 47, p. 205-206. 1956.

LIMA, P. C.; ABREU, A. R. de. *Estatística Experimental - Ensaios Balanceados*. Lavras: FAEPE. 2000. 75 p.

MACHADO, A. A.; DEMÉTRIO, C. G. B.; FERREIRA, D. F.; SILVA, J. G. C. da. *Estatística Experimental: uma abordagem fundamental no planejamento e no uso de recursos computacionais*. 50ª Reunião Anual da Região Brasileira da Sociedade Internacional de Biometria/11º Simpósio de Estatística Aplicada à Experimentação Agrônômica. Londrina, PR. 2005. 290 p.

MOREIRA, D. K. T. *Extrudados Expandidos de Arroz, Soja e Gergelim para Uso em Barras Alimentícias*. 2010. 166p. Dissertação (Mestrado em Ciências dos Alimentos) - Universidade Federal de Lavras, UFLA, Lavras, 2010.

PAIVA, A. P. de. *Estudos Tecnológico, Químico, Físico-químico e Sensorial de Barras Alimentícias Elaboradas com Subprodutos e Resíduos Agroindustriais*. 2008. 131p. Dissertação (Mestrado em Ciências dos Alimentos) - Universidade Federal de Lavras, UFLA, Lavras, 2008.

RAMALHO, M. A. P.; FERREIRA, D. F.; OLIVEIRA, A. C. de. *Experimentação em Genética e Melhoramento de Plantas*. 2ª ed. Lavras: Editora UFLA, 2005. 322 p.

R DEVELOPMENT CORE TEAM. *R: A Language and Environment for Statistical Computing*. Vienna, Austria: R Foundation for Statistical Computing. 2010.

REZENDE, F. A. de. *Aproveitamento da Casca de Café e Borra da Purificação de Gorduras e Óleos Residuários em Compostagem*. 2010. 74p. Dissertação (Doutorado em Agronomia/Fitotecnia) - Universidade Federal de Lavras, UFLA, Lavras, 2010.

RIBEIRO, J. de A. *Estudos Químicos e bioquímicos do Yacon (Samallanthus sonchifolius) in natura e Processado e Influência do seu Consumo sobre Níveis Glicêmicos e Lipídeos Fecais de Ratos*. 2008. 166p. Dissertação (Mestrado em Ciências dos Alimentos) - Universidade Federal de Lavras, UFLA, Lavras, 2008.

SHAPIRO, S. S. AND WILK, M. B. An Analysis of Variance Test for Normality (complete samples), *Biometrika*, London, v.52, n.3-4, p. 591-611, Dec. 1965.

ZIMMERMANN, F. J. P. *Estatística Aplicada à Pesquisa Agrícola*. Santo Antônio de Goiás: Embrapa Arroz e Feijão. 2004. 402 p.